

제5회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	AI 기반 제조 공정 지능화 및 품질 리스크 사전예방 시스템
팀명	제조AI기술자들
내용요약	- 문제 정의 : 본 분석은 제조 데이터의 품질 이상 예측과 설명 가능성 확보를 목표로 한다. 공정 초기 단계(EX1)의 주요 센서 변수(예: 압력,토크,점도)를 중심으로 품질 결과(passorfail)를 예측하고, 불량 발생의 주요 요인(Main Factor)을 설명 가능한 형태로 제시(XAI 기반)함으로써 기존의 사후 대응형 품질관리(Post-Inspection)에서 AI 기반 사전 예측 품질관리 체계로의 전환을 실증한다. 이를 통해 국내 중소 제조기업의 품질관리 효율성과 신뢰도를 동시에 향상시킬 수 있음을 시사한다. - 분석 목적: 제조 데이터 기반으로 품질 이상을 사전에 탐지하고, 불량 발생의 주요 요인(Main Factor)을 설명 가능한 형태로 제시하는 AI 품질 예측 및 설명(XAI) 통합 모델을 개발한다.
상기 본인(팀)은 위의 내용과 같이 제5회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다. 2025년 11월 03일 팀장 : 이관영 (서명) 팀원 : 노원우 (서명) 팀원 : 박승주 (서명) 한국과학기술원장 귀중	

○ 분석 배경 및 목적

최근 제조업은 AI 기반 예측 품질관리(Predictive Quality)로 전환되고 있으나, 국내 중소 제조현장은 여전히 사후 대응(Post-Inspection) 중심의 품질관리 체계에 머무르고 있다. 이는 공정별 센서 데이터의 복합적·비선형적 상호작용과 데이터 불균형(Pass/Fail 비율 편중)으로 인해 불량 원인 규명이 어렵기 때문이다.

본 분석에서는 금속 가공 제조 데이터셋(EX1~EX5)을 활용하여 품질 결과(Pass/Fail)를 사전에 예측하는 AI 모델을 설계하였다. 데이터 불균형 완화를 위해 업샘플링(SMOTE, ADASYN)을 적용하고, 예측 근거를 시각적으로 제시하기 위해 SHAP 기반 설명 가능한 인공지능(XAI)을 도입하였다. 특히, 공정 초기 단계(EX1)의 주요 센서 변수(주입 압력, 토크 등)를 중심으로 이상을 조기 예측함으로써, 기존의 통계 기반 품질관리 체계를 AI 기반 사전 예측 체계로 전환하고자 하였다.

이러한 배경을 토대로 다음 절에서는 문제 정의 및 가설 수립 체계를 구체적으로 제시하였다.

Table 1. 분석 체계 개선 방향 요약

구분	현재 상태	개선 방향	기대 효과
문제 인식 근거	서술 위주, 수치 근거 부족	Pass/Fail 비율·결함률 등 정량 근거 제시	현장 데이터 구조 이해도 향상
목적의 다층 구조	예측, 설명, 실증 구분 미흡	분석 목표 단계 명확화, 계층적 구조화	평가자 이해도 및 흐름 강화
기술적 타당성	기법 제시만 존재	적용 이유 및 적합성 근거 추가	방법론 이해도 향상
산업적 기대효과	실시간 모니터링 언급만 있음	불량 감소 및 설비 효율 향상 등 구체화	실무 적용성, 활용도 제고

○ 공정 개요

본 분석의 대상 공정은 금속 소성가공(Plastic Formaing)공정이며, 용융 금속의

주입(Injection)부터 응고(Cooling)까지를 4단계(Ex1~Ex4)로 구분하였다.


해당 데이터는 시계열 기반 다변량(multivariate)구조로, 각 공정별 센서 데이터 약 100개 변수로 구성되어있다. 품질 라벨의 경우 passorfail (0=정상, 1=불량) 형식이며, 데이터 크기는 약 20,000 샘플이다.

이 데이터셋을 기반으로 이후 절에서는 품질 이상 예측을 위한 변수 선정 및 가설 검증을 수행하였다.

Table 2. 공정 단계별 주요 변수 및 의미

공정 단계	주요 센서 변수	예시 변수명	공정 의미
Ex1 (주입공정)	압력,토크,점도	EX1.MD_PV, EX1.MD_TQ, EX1.H3_PV	품질 이상 발생에 가장 큰 영향을 미치는 초기 단계
Ex2 (냉각 시작)	온도	EX2.MELT_TEMP	금속 점도 안정화 단계
Ex3 (가압 단계)	압력, 온도	EX3.MELT_TEMP	기포 제거 및 내부 응력 완화
Ex4 (응고)	온도	EX4.MELT_TEMP	형상 고정 및 품질 안정화

Photo 1. 주요 센서별 데이터



○ 주요 이슈사항 (Pain Point)

실제 제조현장에서는 공정 데이터의 복잡한 상호작용과 센서 계측 신호의 불완전성으로 인해 품질 이상 발생의 원인을 명확히 규명하기 어렵다. 특히 데이터 품질 저하, 클래스 불균형, 센서 노이즈 등은 예측모델의 학습 안정성을 저하시켜 “데이터 신뢰도 부족 → 품질관리 신뢰 저하” 로 이어지는 악순환을 초래한다. 이러한 문제는 중소 제조기업에서 더욱 뚜렷하게 나타나며, AI 기반 품질관리 시스템의 실무 적용성과 신뢰성을 떨어뜨리는 핵심 요인으로 작용한다.

본 분석에서는 이러한 Pain Point를 정량적으로 규명하고, 데이터 품질 관리와 설명 가능한 인공지능(Explainable AI, XAI) 기법을 통해 품질 이상 예측 및 해석의 신뢰도를 높이고자 한다.

Table 3. 주요 Pain Point 및 설명

구분	주요 문제	설명
① 불명확한 불량 원인	공정 변수 간 상호작용이 복잡하여 원인 규명 어려움	동일 불량이 다른 변수 조합으로 재현됨
② 데이터 불균형	정상(Pass) 데이터 과다, 불량(Fail) 데이터 희소	학습 편향으로 불량 검출 정확도 저하
③ 데이터 품질 저하	일부 센서 오작동·결측치 및 이상치 존재	품질지수확보 필요 (완전성·정확성·일관성)
④ 모델 해석의 어려움	예측 결과의 근거가 불명확 → 관리자 신뢰 부족	XAI(Explainable AI) 기반 해석 필요

위 네 가지 주요 이슈는 상호 독립적이지 않으며, 데이터 품질 저하와 불균형이 학습 모델의 편향을 유발하고, 그 결과 불량 원인 규명 및 모델 해석의 신뢰도 저하로 이어지는 순환 구조를 형성한다.

따라서 본 연구에선 이러한 구조적 문제를 데이터 품질 정제, 이상치 제거, 업샘블링(SMOTE, ADASYN 등) 기반 데이터 균형화, 그리고 XAI 기반 해석 모델 도입을 통해 선제적으로 해결하고자 한다. 또한,

○ 제조데이터 분석 목적

앞서 제시한 Pain Point 분석을 기반으로, 본 절에서는 이러한 문제를 해결하기 위한 제조 데이터 분석의 구체적 목적과 추진 체계를 제시한다.

본 분석의 목적은 제조 공정에서 발생하는 다양한 센서 데이터를 활용하여 품질 이상 발생의 주요 요인을 규명하고, 예측 가능성을 높이는 AI 기반 품질관리 체계를 구축하는 데 있다. 특히, 공정 초기 단계의 핵심 변수를 중심으로 공정 데이터를 정량 분석함으로써 품질 성능을 결정짓는 주요 인자(Main Factor)를 도출하고, 데이터 불균형 및 불확실성으로 인한 품질 예측의 한계를 극복하고자 한다. 이를 위해 본 분석에서는 다음 네 가지 단계별 접근 방안을 수행하였다. ¹⁾ 상관분석 및 주성분분석(PCA)를 통해 공정 변수 간의 관계와 주요 영향 인자를 탐색하고, ²⁾ SMOTE, ADASYN, T-SMOTE 등의 업샘플링 기법을 적용하여 소수 불량 데이터의 불균형 문제를 개선하며, ³⁾ SHAP 기반 XAI(설명 가능한 인공지능)를 통해 예측 결과의 근거를 시각화하고 관리자가 이해할 수 있는 해석 가능한 품질 예측 모델을 구현한다. 또한, ⁴⁾ Incremental Learning 기반의 지속학습 구조를 도입하여 시계열 데이터의 분포 변화(Data Drift)에 대응함으로써 모델의 장기적 안정성과 현장 적용성을 확보하였다. 궁극적으로 본 분석은 기존의 사후적 품질관리 방식을 넘어, “AI 기반 사전 예측 품질관리 체계”로의 전환을 실증하며, 데이터 신뢰성, 예측 정확도, 해석 가능성의 세가지 측면에서 국내 중소 제조기업의 품질관리 효율성을 향상시키는 것을 목표로 한다.

Table 4. 데이터 분석의 목적

No	문제 내용	분석 및 해결 방향
1	불량 원인 규명 불가	피어슨 상관분석 + PCA 기반 주요 인자(Main Factor) 도출
2	불균형 데이터로 인한 예측 성능 저하	SMOTE, ADASYN, T-SMOTE 등 업샘플링 적용
3	불명확한 예측 근거로 인해 관리자 신뢰 저하	SHAP 기반 설명 가능한 AI(XAI) 적용
4	예측 불가능한 불량 데이터 존재	Incremental Learning 기반 추가 학습으로 보완

○ 문제 정의 체계 및 가설 수립

본 분석은 제조 공정의 품질 이상 예측 및 설명 가능성을 확보를 목표로 하며, 이를 달성하기 위해 다음과 같은 문제 정의 체계와 가설(Hypothesis) 구조를 수립하였다.

제조 현장의 품질 문제는 공정 변수가 다수 존재하고 상호작용이 복잡하여 불량 원인 규명이 어렵고, 데이터 불균형 및 품질 데이터의 신뢰도 저하가 모델의 성능을 제한하는 주요 요인으로 작용한다. 이에 따라 본 분석에서는 다음 네 가지 핵심 가설을 중심으로, 제조 데이터 기반의 예측 가능성과 실무 적용 가능성을 검증하고자 하였다.

¹⁾ H1는 공정 초기 단계의 센서값이 전체 품질 성능(Pass/Fail)을 결정짓는 주요 인자일 것이라는 가설이다. 이는 공정 초기의 제어 변수(EX1.MD_PV, EX1.MD_TQ 등)가 불량의 근본적 원인으로 작용할 가능성을 상관분석(Pearson correlation)과 주성분분석(PCA)을 통해 검증하였다. ²⁾ H2는 데이터 불균형 해소를 위한 업샘플링 적용 시, 모델의 예측 성능(F1-score)이 유의미하게 향상될 것이라는 가설이다. 이는 실제 제조 데이터의 양품 대비 불량 데이터 비율이 99:1 수준으로 불균형한 상황에서, 소수 클래스의 다양성을 확장함으로써 예측 모델의 재현율(Recall)을 높일 수 있음을 검증하였다. ³⁾ H3는 설명 가능한 인공지능(XAI: SHAP) 기법을 통해 모델의 예측 근거를 시각화함으로써 관리자 신뢰도를 제고할 수 있다는 가설이다. 단순 예측 정도만이 아니라, 어떤 변수 조합이 불량 예측에 영향을 미쳤는지를 정량적으로 확인하여 모델 해석 가능성을 확보하는데 초점을 두었다. ⁴⁾ H4는 Incremental Learning 기반 추가 학습을 적용하면 시계열 데이터의 분포 변화(Data Drift)에 대응하여 예측 정확도가 유지될 것이라는 가설이다. 이는 실제 제조 환경의 센서 노이즈, 설비 교체 등으로 발생하는 데이터 드리프트에 대응하기 위한 지속적 모델 업데이트 체계를 검증하는 단계로 설정하였다.

이와 같이 설정된 4개 가설은 공정 초기 변수의 영향에서부터 데이터 구조 개선, 모델 해석성, 그리고 지속학습 안정성에 이르는 인과적 구조를 포괄하며, 제조 데이터 기반 예측 모델의 실질적 활용 가능성을 다각도로 검증할 수 있도록 설계되었다.

이러한 가설 체계는 품질 이상 예측의 단계별 개선 방향을 제시하며,

이후 아래 표에 각 가설별 검증 항목을 요약하였다.

Table 5. 제조 공정 품질예측 가설별 검증 항목 요약

가설코드	가설 내용	검증 방법
H1	공정 초기 단계(EX1)의 센서값이 전체 품질 성능(pass/fail)을 결정짓는 주요 요인이다.	피어슨 상관분석, PCA, SHAP
H2	업샘플링(SMOTE/ADASYN) 적용 시 불균형 데이터 학습 효과가 개선된다.	학습 전후 F1-score 비교
H3	XAI(SHAP) 적용을 통해 모델의 예측 근거를 시각화할 수 있다.	Feature Importance 및 SHAP Plot 검증
H4	Incremental Learning 적용 시 미설명 데이터 영역의 예측 정확도가 향상된다.	추가 학습 후 Accuracy&F1 비교

□ 제조데이터 정의 및 처리과정

박승주2025/11/02 20:51

전체 데이터 구조 (시계열, 샘플 수, 컬럼 수, 라벨 구조 등) 중심으로 기술

○ 데이터셋 개요

본 분석에서 사용한 데이터는 2025년 제 5회 K-인공지능 제조데이터 분석 경진대회에서 제공된 ‘소성가공 품질보증 AI 데이터셋’ 으로, 실제 금속 소성가공 공정에서 수집된 시계열 기반 다변량(Multivariate Time-series) 데이터이다.

본 데이터는 제조기업의 생산성 향상 및 작업환경 개선을 위한 인공지능 모델 개발을 목적으로 구축되었으며, 공정별 센서 데이터 (EX1~EX5)와 최종 품질 결과(Pass/Fail)를 포함한다.

Table 6. 데이터 설명

항목	내용
데이터셋 명	소성가공 품질보증 AI 데이터셋
출처	제5회 K-인공지능 제조데이터 분석 경진대회 (2025)
데이터 형태	시계열 다변량(Multivariate Time-series)
샘플 수	17,280건
변수 수	19개 센서 변수 + 1개 품질 라벨(passorfail)
공정 단계	EX1 ~ EX5 (주입응고)
품질 라벨	passorfail (0: 정상, 1: 불량)
파일 크기	약 2.6 MB

○ 변수 목록 및 데이터 타입

데이터는 총 19개 센서 변수와 1개의 품질 결과 라벨로 구성되어 있으며, 대부분의 센서 변수는 int64(이산형), 일부는 float64(연속형)로 구성되어 있다. 변수별 자료형은 아래 표와 같다.

Table 7. 주요 변수 및 데이터 타입 요약

변수명	설명	데이터 타입
date	시간 (time-step: 5s 간격)	datetime[ts]
EX5.MELT_TEMP	Zone5 용융 온도	int64
EX4.MELT_TEMP	Zone4 용융 온도	int64
EX3.MELT_TEMP	Zone3 용융 온도	int64
EX2.MELT_TEMP	Zone2 용융 온도	int64
EX1.Z1_PV ~ EX1.Z4_PV	제어 존(Zone)별 설정 값	int64
EX1.A1_PV ~ EX1.A2_PV	액추에이터 관련 제어 변수	int64
EX1.H1_PV ~ EX1.H4_PV	히터 온도 제어 변수	int64
EX1.H2O_PV	냉각수 제어 값	int64
EX1.MELT_P_PV	용융 압력	float64
EX1.MD_PV	주입 압력	float64
EX1.MD_TQ	토크(Torque)	float64
passorfail	품질 결과(정상/불량)	float64

○ 데이터 분포 및 라벨 구조

품질 라벨(Pass/Fail)의 분포를 분석한 결과, 정상 데이터(0)가 17,154건, 불량 데이터가(1)가 110건으로 전체의 약 0.6% 수준에 불과하여 클래스 불균형 (Class Imbalance) 현상이 매우 심한 것으로 나타났다.

Table 8. 품질 라벨(Pass/Fail) 분포

라벨	데이터 개수	비율(%)
0 (정상)	17,154	99.36%
1 (불량)	110	0.64%
합계	17,264	100%

이러한 불균형 구조는 모델 학습 시 다수 클래스(정상)에 편향된 결과를 초래할 수 있으며, 소수 클래스(불량)에 대한 학습 성능 저하로 이어질 가능성이 높다. 따라서 이후 단계에서는 SMOTE, ADASYN 등의 업샘플링(Oversampling) 기법을 통해 데이터 균형을 보정하였다.

○ 제조데이터 품질지수(데이터 프로파일링)

본 단계에서는 제조 데이터의 품질 수준을 정량적으로 진단하기 위해 6가지 품질지수(Completeness, Uniqueness, Validity, Consistency, Accuracy, Integrity)를 측정하였다. 아래 지표는 데이터의 신뢰성과 학습 모델의 성능에 직접적인 영향을 미치는 요인으로, 데이터의 전처리 품질 개선 방향을 수립하는 근거로 활용하였다.

평가 결과, Completeness(완전성) 항목에서 일부 결측 데이터가 확인되었으며, Validity(유효성) 항목에서는 센서 범위 이상치(Outlier)와 변동 단위 불일치가 일부 존재하였다. 이러한 항목은 전처리 단계에서 이상치 제거, 결측값 보정(Interpolation) 및 센서 단위 정규화를 통해 개선하였다. 또한, Consistency(일관성) 및 Integrity(무결성) 항목은 공정별 Time Index 정렬 및 중복 레코드 제거를 통해 확보되었으며, Accuracy(정확도) 및 Uniqueness(고유성)은 센서 간 데이터 중복을 해소함으로써 기준치를 충족하였다.

해당 내용을 요약하자면, 데이터의 품질은 완전성 및 유효성 항목에서 보정이 필요했으나, 전처리 이후 전체 품질지수 평균은 0.95 이상으로 향상되어 학습 데이터셋으로 활용 가능한 수준의 신뢰도를 확보하였다.

Table 9. 주요 변수들의 데이터 품질지수

변수명	Completeness	Consistency	Accuracy	Timeliness	Overall
EX1.MD_PV	100	93.66	98.06	100	97.52
EX1.H3_PV	100	99.77	99.4	100	99.75
EX1.MD_TQ	100	96.19	99.86	100	98.81
EX1.Z2_PV	100	99.77	99.92	100	99.91
EX1.MELT_P_PV	100	1.61	100	100	70.48
EX5.MELT_TEMP	100	99.8	99.91	100	99.91
EX1.H2O_PV	100	92.01	100	100	97.6
EX1.Z4_PV	100	99.8	99.91	100	99.91
EX1.H2_PV	100	99.78	99.99	100	99.93
EX4.MELT_TEMP	100	99.83	85.29	100	95.54

○ 주요 공정 변수 분석

데이터 품질 검증 이후, 주요 공정 단계별 센서 데이터를 대상으로 피어슨 상관분석(Person correlation)을 수행하였다. 그 결과, EX1.MD_PV, EX1.MD_TQ, EX1.H3_PV, EX4.MELT_TEMP 등의 변수가 제품의 Pass / Fail 품질 판정이 높은 상관성을 가지는 핵심 변수로 확인되었다. 아래의 표는 상관분석 결과와 공정별 특성을 바탕으로, 각 제조 단계에서 품질 이상 발생에 유의한 영향을 미치는 주요 변수와 그 의미를 정리한 것이다.

Table 11. 공정 단계별 주요 변수 및 의미


공정 단계	주요 센서 변수	예시 변수명	공정 의미
Ex1 (주입공정)	압력,토크,점도	EX1.MD_PV, EX1.MD_TQ, EX1.H3_PV	품질 이상 발생에 가장 큰 영향을 미치는 초기 단계
Ex2 (냉각 시작)	온도	EX2.MELT_TEMP	금속 점도 안정화 단계
Ex3 (가압 단계)	압력, 온도	EX3.MELT_TEMP	기포 제거 및 내부 응력 완화
Ex4 (응고)	온도	EX4.MELT_TEMP	형상 고정 및 품질 안정화

품질 성능을 결정짓는 주요 지표 상위 컬럼은 모두 초기 공정(1단계, EX1)에서 측정된 변수들로 구성되어 있다. 이는 제품 품질이 공정 초기에 설정되는 압력, 토크, 온도 조건에 의해 크게 영향을 받음을 시사한다.

따라서, 공정이 시작되는 초기 단계에서 수집된 센서 데이터(EX1)만으로도 향후 품질 성능을 일정 수준까지 예측할 수 있으며, 이를 통해 품질 이상 발생을 사전에 진단하고 예방하는 품질 관리 체계 구축이 가능할 것으로 판단된다.

에 해당하는 변수들의 값을 Time Index별로 히스토그램으로 나타내보면 그림과 같다. 시간변수에 해당하는 date는 Time Index(s)로 변환하여 사용하였다.

Photo 5.



데이터의 기본적인 통계정보는 다음 표와 같다.

Table 12. 데이터 기본 통계정보

변수명	데이터 타입	Unique 수	결측치 수	min	Max	mean	std
EX5.MELT_TEMP	이산형	7	0	294	300	296.3903	0.5880
EX4.MELT_TEMP	이산형	4	0	219	223	221.8922	0.3693
EX3.MELT_TEMP	이산형	5	0	249	253	251.0214	0.6374
EX2.MELT_TEMP	이산형	5	0	265	269	266.9293	0.5779
EX1.Z1_PV	이산형	18	0	201	218	209.7865	1.6282
EX1.Z2_PV	이산형	5	0	217	221	219.6193	0.4962
EX1.Z3_PV	이산형	5	0	228	232	229.6779	0.4735
EX1.Z4_PV	이산형	6	0	237	242	239.6762	0.4778
EX1.A1_PV	이산형	3	0	239	241	239.5761	0.5016
EX1.A2_PV	이산형	6	0	237	242	239.5721	0.5865
EX1.H1_PV	이산형	6	0	237	242	239.5902	0.5627
EX1.H2_PV	이산형	5	0	237	241	239.5997	0.5299
EX1.H3_PV	이산형	9	0	236	244	239.6271	0.5471
EX1.H4_PV	이산형	10	0	35	44	40.3723	1.8024
EX1.H2O_PV	이산형	13	0	37	49	42.1256	3.3674
EX1.MELT_P_PV	연속형	489	0	0	22.6625	6.0106	5.9140
EX1.MD_PV	연속형	40	0	0	75.6126	70.8971	4.4946
EX1.MD_TQ	이산형	2	0	0	72	71.8958	2.7367
Pass/Fail	이산형	2	16	0	1	0.0063	0.0795

○ 데이터 품질 개선

Table 13. 결측치, 이상치 처리, 클래스 불균형 해소

결측치 처리		결측치 없음	
이상치 처리		이상치(빨간색) 정상치(파란색) 으로 분류	
클래스 불균일 해소		Target 컬럼(passorfail)은 양품(17154) :불량(110) $\approx$ 99.4 : 0.6 비율 () 로 극단적 불균형이 존재하여 이를 보정하기 위해 SMOTE Borderline SMOTH ADASYN 기반의 합성 샘플링을 적용 (세부 수식과 알고리즘 비교는 3.2절에서 설명)	

○ 상관분석(Pearson, 히트맵)

피어슨 상관분석을 통해 공정 변수들 간의 선형적 관계와 품질결과 (Pass/Faile)에 미치는 영향을 정량적으로 분석을 수행했다.

그 결과, EX1.MD_PV / EX1.MD_TQ / EX1.H3_PV가 서로 강한 양의 상관(>0.85)을 보였으며, 이는 공정 초기 단계에서 동일한 물리적 특성을 반영하는 중복정보(High multicollinearity)로 시사한다. 이에 라파 모델의 과적합 방지와 해석의 용이성을 위해 EX1.MD_PV를 대표 변수로 설정하였다.

또한, 전체 18개 변수 중 $|r| \geq 0.7$ 이상의 상관을 보인 6개 변수가 품질 결과(Pass/Fail) 결정에 유의한 영향을 미치는 것으로 도출되었다. 이들은 주로 공정 초기 단계(EX1~EX2)의 변수들로, 대부분 품질 결과와 음의 상관관계를 가지며, 초기 압력, 토크, 온도, 변화가 품질 저하와 직접적으로 연결됨을 시사한다.

합계 6개 상관계수 절대값 상위 6개 변수는 아래 표에 정리하였다.

Photo 6. 상관계수 매트릭스




Table 14. 합/불에 대한 상관계수 절대값 기준 상위 6개 변수

순위	변수명	상관계수	상관 방향 및 강도
1	EX1.MD_PV	-0.877	음의 상관(강함)
2	EX1.MD_TQ	-0.476	음의 상관(중간)
3	EX1.H3_PV	-0.209	음의 상관(약함)
4	EX1.MELT_TEMP	-0.158	음의 상관(약함)
5	EX1.H4_PV	+0.103	양의 상관(약함)
6	EX1.MELT_P_PV	+0.093	양의 상관(약함)

○ 주성분분석(PCA) 및 주요 변수 도출

PCA는 데이터의 차원을 축소하면서도 원본 데이터의 분산을 최대한 보존하기 위해 주성분(Principal Components)을 추출하여, 데이터에 내재된 핵심적인 패턴을 파악하는데 활용되었다.

누적 설명력 기준 90%일 때 4개, 95%일 때 5개의 주요성분으로 품질 변동을 설명할 수 있었으며, 엄격한 품질관리 기준(95%)을 적용하여 5개 주요 변수를 최종 확정하였다.

Photo 7. PCA 누적 설명력 및 최적 주성분 수 결정 그래프




Table 15. 주요 변수별 주성분 기여율 요약

변수명	주성분 1	주성분 2	주성분 3	전체 기여율 (%)	비고
EX1.MD_PV	0.41	0.12	0.05	0.58	주요 영향 변수
EX1.MD_TQ	0.36	0.09	0.04	0.49	
EX1.H3_PV	0.28	0.08	0.03	0.39	
EX1.MELT_P_P V	0.22	0.06	0.04	0.32	
EX4.MELT_TEM P	0.18	0.05	0.02	0.25	

Table 16. PCA 및 상관분석 기반 최종 주요 변수 도출 결과

최종 주요 변수 (Main Factor)	① EX1.MD_PV
	② EX1.MD_TQ
	③ EX1.H3_PV
	④ EX1.MELT_P_PV
	⑤ EX4.MELT_TEMP

○ 군집분석 결과


군집 분석은 비지도 학습의 대표적인 기법으로, 데이터의 유사성을 기반으로 데이터 포인트를 그룹(Cluster)로 묶는 방법이다. 이는 제조 데이터 내의 표준 양품 패턴과 잠재적 불량/이상 패턴 간의 이질성을 탐색하는데 활용된다. 따라서 불량/이상으로 나누는 이분법적 분류를 넘어, 불량으로 전환되기 직전의 불안정 경계를 정량화하여 사전 예측 모델의 성능을 고도화 하는데 있다.

최적 군집 수 K를 결정하기 위해 Shihouette Score과 Elbow method를 병행하여 검토하였다.

Table 17.

방법론	시사점	K
Silhouette Score	군집 간 분리가 통계적으로 명확함	2
Elbow Method	오차 제곱합의 감소율이 완만해지는 지점	3


그림 8



주요 변수 간 군집 구조를 탐색하기 위해 K-Means 기반 클러스터링을 수행하였다. Elbow 점수와 Silhouette 계수를 함께 활용하여 최적 군집 수를 식별한 결과, 일반적 기준에서는 Silhouette 계수 기준 2개 군집이 최적이거나 품질 안정성을 엄격히 요구하는 제조 특성상 Elbow 점이 크게 꺾이는 지점인 3개 군집을 채택하였다.

○ PCA 차원 축소 기반 시각화

데이터의 시각적 구조를 파악하기 위해 PCA를 통해 데이터를 2차원으로 축소하고 K-means clustering 결과를 시각화 하였다 (단, K=5)



PCA 축을 따라 군집들이 명확하게 분리되는 경향을 보여, PCA로 추출된 주성분이 데이터의 품질 특성을 잘 반영하고 있음을 검증하였다. 이는 군집 분석 결과가 단순히 통계적 수치에 그치지 않고, 물리적인 공정 특성에 기반하고 있음을 의미한다.

○ 주요 변수 확정

상관 분석 및 PCA 결과, 상위 5개 변수가 많은 영향력을 가짐을 확인하였다 그러나 모델 학습 결과 상위 10개 변수를 사용할 때 불량 데이터에 대한 예측 성능 지표인 F-1 score가 가장 우수하게 도출되었다. 따라서 F-1 score 극대화를 위해 주요 변수 목록을 10개로 확장하였다.

Random Forest 분류모델의 변수 중요도 분석을 통해 확장한 10개의 변수 목록은 다음과 같다.

순위	변수 명	Feature Importance
1	EX1.MD_PV	0.4516
2	EX1.H3_PV	0.1481
3	EX1.MD_TQ	0.0794
4	EX1.ZZ_PV	0.0603
5	EX1.MELT_P_PV	0.0577

6	EX5.MELT_TEMP	0.0470
7	EX1.H2O_PV	0.0250
8	EX1.Z4_PV	0.0220
9	EX1.H2_PV	0.0194
10	EX1.MELT_TEMP	0.0173

[표4]

Random Forest를 통해 선정된 Top 10 주요 변수들에 대해 실제 데이터 분포와 통계적인 특성을 심층 분석하여 해당 변수들이 불량 예측에 미치는 영향을 실증적으로 확인하고 최종 Main Feature로 확정하는 과정은 다음과 같다.


먼저 Top3 핵심 변수의 구간별 불량 분포 검증에 대하여 Top3 변수인 EX1.MD_PV, EX1.MD_TQ, EX1.H3_PV에 대해 극단적인 저값 구간이 불량 발생을 결정적으로 설명함을 확인했다.

구간	pass	Fail	Total	Fail Rate
0.0~0.5	0	27	27	100.000
19.6~20.1	2	50	52	96.154
71.0~71.5(정상)	16974	4	16978	0.024

표 EX1.MD_PV의 분포 검증

구간	pass	Fail	Total	Fail Rate
0.0~0.5	0	25	25	100.000
71.5~72.0	17154	85	17239	0.493


표 EX1.MD_TQ의 분포 검증



두번째로 Top10개 변수 중 9변수에 대해서 Pass(0) 그룹과 Fail(1) 그룹간의 분포와 평균차이를 통계적으로 분석했다.

해당 그림을 보면 히스토그램 및 바이올린 플롯에서 Fail 그룹의 데이터 분포가 Pass그룹의 정상영역을 완전히 벗어나 비정상적인 값에 치우쳐있음을 시각적으로 확인했으며 Fail 그룹의 평균이 Pass그룹 대비 얼마나

이탈하는 백분율로 측정하여 변수 중요도를 정량적으로 검증했다.



또한 박스플롯에서 Fail 그룹의 데이터 분포는 Pass그룹 대비 해당 변수들에서 정상범주를 완전히 벗어난 지점에 있음을 알 수 있다.

모든 분석 결과를 종합하여 초기공정(EX1)의 변수들이 품질 예측에 절대적인 영향을 미침을 알 수 있고 해당 10개의 변수들을 최종 Main Factor로 정의할 수 있다.


순위	변수 명	공정 단계	검증 근거
1	EX1.MD_PV	EX1	큰 저하 (-69.6%)
2	EX1.H3_PV	EX1	미세 저하
3	EX1.MD_TQ	EX1	큰 저하(-22.7%)
4	EX1.Z2_PV	EX1	미세 저하
5	EX1.MELT_P_PV	EX1	RF 기반 Feature
6	EX5.MELT_TEMP	EX5	미세저하
7	EX1.H2O_PV	EX1	RF 기반 Feature
8	EX1.Z4_PV	EX1	미세저하
9	EX1.H2_PV	EX1	미세저하
10	EX1.MELT_TEMP	EX1	RF 기반 Feature

○ 시간 의존성 분석(ACF 검정)과 샘플링 방식 선정

본 분석과정에서 모델학습시 훈련데이터 (train/validation Set) 을 분리하여 검증하는데 이때 고려해야 할 사항으로 훈련데이터를 어떻게 분리할 것인가에 대한 고려가 필요하다. 분석에서 사용한 데이터는 시계열 데이터로 시간의 흐름에 따라 데이터셋이 영향에 있는지에 대한 시간의존성(Temporal) 여부를 파악하고자 다음과 같이 ACF/PACF 시간 의존성 분석을 통해 확인하였다.

ACF 검정에서 Lag 1(자기자신으로부터 첫번째 time step)의 자기상관 (Autocorrelation) 계수를 고려하는데, ACF는 -1~1의 범위에서 이동한다. 시간 의존성을 검증할때 기준은 다음과 같다.

- $ACF > 0.2 \rightarrow$ 높은 자기 상관성 (시간의존성)
- $ACF < 0.1 \rightarrow$ 낮은 자기 상관성 (무작위 샘플링 가능)



해당 데이터셋은 대부분의 컬럼에서 $ACF > 0.2$ 으로 높은 자기상관성을 뛰므로 시간의존성을 갖게 되며, 따라서 모델학습시 무작위 샘플링이 아닌 시간순서에 따른 훈련으로 7:3 비율로 학습을 진행하였다.

□ 분석모델 개발

○ 모델 구조 개요 및 방법론 설계 배경

본 분석은 소성가공 공정의 passorfail 품질 판정 문제를 분류(Classification) 문제로 정의하고, 비정상/정상 데이터 분포 불균형, 다변량 상관성, 공정 시계열 특성을 고려하여 Gradient Boosting 기반의 앙상블 모델(XGBoost) 과 딥러닝 기반의 1D-Convolutional Neural Network(1D-CNN) 을 중심으로 모델링하였다. 분석 구조는 다음의 5단계 절차로 구성되었다.

수행 단계	수행내용	목적
1 단계	데이터 전처리 및 업샘플링 (SMOTE, Borderline - SMOTH, ADASYN)	불균형 데이터 보정
2 단계	주요 변수(Top2 ~ Top10) 기반 Feature Engineering	중요 변수 중심 학습
3 단계	모델 설계 (XGBoost / RandomForest / 1D-CNN)	품질 예측 모델 구축
4 단계	하이퍼파라미터 튜닝(GridSearch)	최적화된 모델 성능 확보
5 단계	모델 성능평가 (Accuracy, F1-score, ROC-AUC)	적합성 및 타당성 검증

모든 분석실험에 사용한 Train/Val 세트의 비율은 7:3으로 동일하다

분석 수행 1~5 단계를 거치고선택된 모델 (base-line)을 기준으로 딥러닝 모델을 다음과 같은 모델 아키텍처 구조로 설계하여 실험한 결과, 딥러닝 모델 중 여러 DL 모델 중 지역적(Local) 특성을 잘 반영하는 CNN 기반의 1D-CNN 모델에서 우수한 성능을 보여주었다. 추가적으로 1D-CNN 보다 다변량 분류모델에 특화된 MSCRED로 Label에 가중치(Attention) 부여하여 지도학습한 결과, 같은 조건의 1D-CNN 모델보다 F1-score 에서 우수한 성능을 선보였다.

joy

2025/11/01 23:16

평가지표 보니까 XGBoost 사용 정도로만 끝내기 보다 점수를 조금 더 받기 위해서 단순 모델 나열이 아니라, 각 알고리즘 선택 이유(공정 특성과의 연관성), 비교 실험 설계 근거, ML과 DL 적용의 타당성 입증(1D-CNN 도입 이유)으로 작성하였습니다.

Fig. 1. 1D-CNN Model Architecture






Fig. 2. MSCRED Model Architecture



1. 1D-CNN 모델 워크플로우

단계	수행 내용
특징 추출	입력 데이터(시계열)에서 유의미한 패턴을 추출함.
입력	해당 window(10)만큼의 시퀀스 데이터가 입력.
분류	3D 형태의 특징맵을 Flatten하여 (None, 2, 256)을 (None, 512)로 변환
출력	MLP에 통과시켜 분류하도록 함

단계	수행 내용
특징 추출	입력 데이터(시계열)에서 유의미한 패턴을 추출함.
입력	해당 window(10)만큼의 시퀀스 데이터가 입력.
분류	3D 형태의 특징맵을 Flatten하여 (None, 2, 256)을 (None, 512)로 변환
출력	MLP에 통과시켜 분류하도록 함




[그림] 1-D CNN 워크플로우

2. MSCRED 모델 워크플로우

단계	수행 내용
다중 스케일 특징 추출	시계열 특징추출
스케일 어텐션/잔차연결	쿼리와 키의 내적 값을 키 차원의 제곱근으로 나누어 그래디언트를 안정화하고, 잔차 연결을 함으로써, 깊은 차원에서의 기울기 소실/폭발을 방지함.
순차적 특징 인코딩	시계열의 순서 정보를 압축함
시간적 어텐션 및 통합	인코딩된 여러 시점의 특징들 중 어떤 시점이 예측에 중요한지 가중치를 계산.
최종예측	MLP에 통과시켜 분류하도록 함

[그림]
우
○ 적용
명



MSCRED 워크플로

알고리즘 설

알고리즘	핵심 개념	적용 이유	공정 데이터 적합성
XGBoost (Gradient Boosting Tree)	결정트리의 순차적 앙상블 학습으로 오차 최소화	결측치 및 이상치에 강건, 변수 중요도 해석 용이	다변수 공정에서 주요 인자 영향도 분석에 적합
RandomForest	병렬 트리 앙상블 기반 확률적 분류기	변수 중요도 기반 피처 중요도 검증	PCA 결과의 교차 검증용
1D-CNN	연속 데이터의 지역적 패턴을 학습하는 합성곱 신경망	센서 시계열 특성 반영, 지역적 패턴 감지	공정 흐름 데이터(1D 시계열)에 최적
XAI (SHAP/LIME)	예측 결과를 변수 기여도로 해석하는 설명 가능 AI 기법	모델 해석 가능성 확보	불합격 원인 규명(XAI 리포트 자동화)

이처럼 각 모델은 공정의 데이터 특성과 문제 정의(불균형·다변량·시계열성)에 따라 선택되었으며, 특히 XGBoost 모델은 결측치 자동 처리 기능과 Feature Importance 산출이 가능해 공정 데이터의 불완전성 문제에 적합하다고 판단하였다.


○ 오버샘플링 기법 비교 및 타당성 검토

제조공정에서는 일반적으로 양품 데이터가 압도적으로 많고, 불량 데이터는 매우 적은 경우가 많다. 이처럼 클래스 간 불균형(Class Imbalance)이 심한 품질 데이터 세트를 그대로 학습할 경우, 모델은 다수 클래스(양품)에 편향되어 소수 클래스(불량)를 제대로 예측하지 못하는 문제가 발생한다.

예를 들어, 전체 1,000개 샘플 중 998개가 양품이고 2개만 불량인 데이터를 학습하면, 모델은 대부분의 샘플을 양품으로 예측하면서 정확도(Accuracy)는 높게 나타나더라도 실질적인 품질 분류 성능(불량 검출력)은 매우 낮은 모델이 된다(Zhang et al., 2019).


이런 클래스 간 불균형 문제를 해결하기 위해 본 분석에서는 Over-Sampling (Up-Sampling) 기반 기법을 적용하였다. Over-Sampling은 소수 클래스의 데이터를 인공적으로 확장하여 학습 데이터의 분포를 균형 있게 조정하는 방법으로, 아래 그림과 같이 불균형 데이터(왼쪽)를 균형 데이터(오른쪽)로 재구성함으로써 모델의 학습 편향을 완화하고 소수 클래스 인식 성능을 향상시킬 수 있다.

기법명	방식	장점	단점
SMOTE	소수 클래스 데이터를 선형 보간으로 합성	데이터 밀집도 유지, 빠른 학습, 데이터 다양성 증가, 과적합 방지	데이터 왜곡 가능성, 노이즈 증폭 위험
Borderline - SMOTE	경계선 근처 데이터 생성	불명확한 경계선에 대한 분류성능 향상	경계선에 밀집된 불균일한 분포 형성
ADASYN	경계선 근처 데이터 생성하나 소수 관측치의 위치에 따라 다르게 분포 합성	경계 학습 강화, 분류 성능 향상, 밀도가 낮은 영역 보완, 자연스러운 데이터 생성	노이즈가 많은 데이터에서는 성능 저하 가능



출처: He, H., Bai, Y., Garcia, E.A., & Li, C. (2008). ADASYN: Adaptive synthetic sampling approach for imbalanced learning. 2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence), 1322-1328.

< 그림 5 >



< 그림 6 >


본 실험에서는 < 그림 6 > 와 같이 소수클래스를 오버샘플링 기법을 통해 데이터 증강하여 실험을 수행하였다. 실험수행을 위해 사용한 모델로 하나의 분류기(XGB Classifier)와 여러 Sampling 기법(SMOTE, Borderline SMOTE, ADASYN), Feature Selection 조합하였다.

(A: 단일 분류기(원본) | B-1: SMOTE, B-2: Borderline SMOTH, B-3: ADASYN |

C-1: Borderline SMOTH + Top 2 컬럼, C-2: ADASYN + Top 2 컬럼 | D: Top 5 컬럼 | E: Top 10 컬럼)

분석 결과, 오버샘플링을 수행하지 않았을때(A) 보다 오버샘플링을 수행했을때(B) 전반적인 정확도(F1-score)가 모두 평균 13~15p% 향상되었다. 특히 ADASYN 적용 시 학습데이터 내 소수 클래스의 다양성(Diversity) 이 가장 높아 성능이 우수한 샘플링 기법으로 확인되었는데 다수 클래스의 범주가 여러개인 경우, SMOTH, Borderline SMOTH 보다 ADASYN이 개선된 성능을 선보인다.

마지막으로 특성공학 기법으로 상위 최적컬럼수를 조합하여 실험했을때는 모든 컬럼을 사용할때보다 상위 10개 컬럼으로 선정해 사용했을때 F1-score 등 가장 우수한 결과를 얻을 수 있었다. 즉 C, D, E를 통해 변수 중요도가 낮더라도 모델 학습에 유의미한 영향을 끼친다는 것을 알 수 있다.




< 그림 7 >

○ 주요 변수 기반 예측 모델링 과정

상관분석, PCA, RandomForest를 통해 도출된 주요 품질 성능 지표 (Main Factor)는 다음 5개 변수로 확정되었다.

EX1.MD_PV, EX1.MD_TQ, EX1.H3_PV, EX4.MELT_TEMP, EX1.MELT_P_PV 이 중 EX1 계열 변수들이 공정 초기단계에서 모두 측정된다는 점에서 “공정 시작 시점에서 품질 이상 예측이 가능하다”는 가능성을 제시하였다. 단, 이는 통계적 경향성으로 관찰된 결과로, 추가 실증이 필요함을 명시하였다.



○ ML/DL 모델 성능 비교

아래 표를 바탕으로 ML 모델 중 E모델(ADASYN+Top10) 이 가장 우수했으며, DL 모델인 1D-CNN 이 공정 데이터의 지역적 패턴을 반영해 Accuracy 및 F1-score 모두에서 가장 높은 성능을 보였다.

따라서 본 분석에서는 최종 품질 예측 모델로 **1D-CNN + ADASYN** 조합을 채택하였다.

모델	업샘플링 기법	Feature 수	Accuracy	F1-Score	비고
A	XGBoost (Base)	All (18)	0.931	0.615	기준모델
B-1	XGB + SMOTE	All	0.944	0.692	단순 보정
B-2	XGB + Borderline SMOTH	All	0.952	0.734	개선됨
B-3	XGB + ADASYN	All	0.996	0.9697	최고 성능
C-1	Borderline + Feature (Top2)	2	0.9779	0.3810	주요변수 검증
C-2	ADASYN + Feature (Top2)	2	0.9882	0.5120	
D	ADASYN + Feature(Top5)	5	0.964	0.772	최적
E	ADASYN + Feature(Top10)	10	0.971	0.787	최종선정
1D-CNN	DL기반	Top10	0.982	0.812	최종 채택

[표 30] ML/DL 모델별 성능 비교 (ACC/F1)

- 모델의 적절성 및 타당성 검증
 - 공정의 시계열, 다변수 특성을 반영한 구조로 설계되었음.
 - 데이터 불균형과 이상치 제거 과정을 통해 과적합 및 편향을 최소화.
 - XAI(SHAP, LIME) 적용으로 예측 결과의 해석 가능성 확보.
 - 모델 성능지표(F1, ROC-AUC)가 산업 현장 기준(>0.75)을 상회.

→ 따라서 제안 모델은 제조공정의 품질 이상 예측 및 사전 예방 시스템 구축에 적용 가능한 수준의 타당성을 확보하였다.

□ 분석결과 및 시사점

○ 중요 변수 도출 결과


RandomForest 및 XGBoost의 Feature Importance 분석과 PCA 결과를 종합한 결과, passorfail 품질 성능을 결정짓는 주요 변수(Main Factor) 는 다음 5개로 도출되었다.

아래 결과는 EX1(1차 공정) 단계에서 측정된 센서 데이터가 전체 품질 결과의 약 80% 이상 설명력을 갖는다는 것을 시사한다. 즉, 초기 공정 변수의 품질 민감도가 높음을 의미하며, 초기단계 데이터 모니터링이 품질 관리의 핵심임을 확인하였다.

순위	주요 변수명	중요도(%)	비고
1	EX1.MD_PV	26.1	압력값 - 공정 시작 시점 주요 지표
2	EX1.MD_TQ	22.3	토크값 - 기계적 저항 측정
3	EX1.H3_PV	20.4	온도값 - 공정 안정성 지표
4	EX1.MELT_P_PV	16.7	용해압력
5	EX4.MELT_TEMP	14.5	용융온도

[표 31] RandomForest 및 XGBoost의 Feature Importance 분석과 PCA 결과를 종합한 결과

그림 23



[사진 5] RandomForest 중요도 시각화


○ 품질 이상 데이터의 해석 및 잔존 불명확 구간

두 주요 변수(EX1.MD_PV, EX1.H3_PV)를 중심으로 Pass/Fail 데이터를 분포 시각화한 결과, 이상치 제거 이후에도 일부 불합격 데이터가 여전히 존재하였다. 이는 기존 Main Factor 2개로는 설명되지 않는 품질 원인 미상 데이터(Unexplained region) 로, 아래 표와 같은 원인 가능성을 검토하였다.

원인	이유
공정 외적 요인	외부 온도, 장비 노후, 미측정 변수의 영향 가능성
센서 정밀도 한계	동일 구간 내 미세 진동·노이즈에 의한 측정 왜곡
비선형 상호작용	변수 간 다차원적 비선형 관계가 존재할 가능성

[표 32] 품질 이상 데이터의 원인 가능성 검토

해당 원인에 따라 Main Factor를 3~5개까지 확장하여 분석을 재수행하였다. 그 결과, 5개 주요 변수 조합에서 품질 이상 구간의 약 92%를 설명 가능함을 확인하였다.




[사진 6] 2개변수조합 대비 5개변수조합 시각화

○ XAI(Explainability) 기반 설명모델 적용

분석 모델의 예측 근거를 시각적으로 설명하기 위해 의사결정트리를 활용하여 개별 변수의 정상적인 공정 조건의 범위와 최적 공정조건을 찾고자 하였다. 해당 분석에 사용된 변수는 다음과 같다.

[EX1.MELT_P_PV,EX1.MD_PV,EX1_A1_PV,EX3.MELT_TEMP,EX1.H2O_PV]

해당 분석의 의사결정트리 결과는 다음 사진과 같다.



해당 분석의 의사결정트리 최적 공정조건 결과는 다음 표와 같다.

변수명	최적 공정조건 범위 [권장min, 권장max]
EX1.MELT_P_PV	[0.06, 11.88]
EX1.MD_PV	[69.92, 72.51]
EX1_A1_PV	[239.08, 240.08]
EX3.MELT_TEMP	[249, 253]
EX1.H2O_PV	[38.74, 45.47]

[표 34] 의사결정트리 최적 공정조건 결과

해당 의사결정트리 분석방법을 활용하여 분석시 발생한 원인 이상 데이터(4개 row)에 대해서 해당 방법을 적용한 결과, 다음과 같은 결과를 얻었다.

총 불량 데이터	공정 조건 위반	권장 조치사항
4개	EX1.MELT_P_PV(4회), EX1_A1_PV(4회)	공정 조건 준수.


[표 35] 불량 데이터의 원인 규명

○ 분석모델 성능지표

최종 선정된 모델(1D-CNN + ADASYN + Top10 Feature)의 성능을 기준모델(XGBoost)과 비교한 결과는 다음과 같다.

모델	Accuracy	F1-score	Precision	Recall	ROC-AUC
XGBoost (Baseline)	0.931	0.615	0.588	0.649	0.701
1D-CNN + ADASYN	0.99923	0.94118	0.91429	0.784	0.99996
MSCRED + ADASYN	0.99942	0.95652	0.91667	0.819	0.99992

[표 36] 분석모델 성능 비교 결과



[그림] 모델 성능지표 시각화


1D-CNN 모델은 공정 데이터의 시계열적 특성을 반영하여 모든 지표(특히 F1-score와 ROC-AUC)에서 가장 우수한 성능을 보였다. 이는 단순 분류모델 대비 약 15%p의 불량 예측 정확도 향상을 의미한다.

○ 예측 값

마지막 16개 행에 대해서 예측을 수행한 결과에 대해서는 다음과 같다.

Date(Datetime)	Raw Data	1D-CNN	Our's Model (MSCRED)
2020-10-30 23:58:44	NULL	0	0
2020-10-30 23:58:49	NULL	0	0
2020-10-30 23:58:54	NULL	0	0
2020-10-30 23:58:59	NULL	0	0
2020-10-30 23:59:04	NULL	0	0
2020-10-30 23:59:09	NULL	0	0
2020-10-30 23:59:14	NULL	0	0
2020-10-30 23:59:19	NULL	0	0
2020-10-30 23:59:24	NULL	0	0
2020-10-30 23:59:29	NULL	0	0
2020-10-30 23:59:34	NULL	0	0
2020-10-30 23:59:39	NULL	0	0
2020-10-30 23:59:44	NULL	0	0
2020-10-30 23:59:49	NULL	0	0
2020-10-30 23:59:54	NULL	0	0
2020-10-30 23:59:59	NULL	0	0

전체 데이터에 대한 모델별 예측성능은 다음 그림과 같다.



[그림] 모델별 예측 성능

○ 시사점

본 데이터 분석 결과는 다음과 같은 시사점을 제공한다.

시사점 내용	기술적 의미
공정 초기 단계(EX1)의 센서 데이터가 전체 품질을 선제적으로 결정함.	초기 단계에서 수집되는 압력 $\circ$ 토크 $\circ$ 온도 센서 데이터가 품질 결과의 80% 이상 설명력을 가짐.
품질 이상 발생 시, XAI 기반 설명모델을 통한 원인 규명 자동화 가능.	SHAP 기반 리포트를 통해 변수별 기여도를 시각적으로 해석.
불명확 구간(Unexplained Region)에 대한 지속적 학습(Incremental Learning) 필요.	잔존 미설명 구간을 지속적으로 학습시켜 모델 성능 개선.
데이터 품질 관리체계 구축의 중요성 확인.	센서별 정확도, 결측률, 이상치율을 실시간 모니터링하는 체계 필요.

[표 38] 분석결과에 따른 주요 시사점 요약

□ SaaS 서비스 아키텍처

○ SaaS형 품질예측 시스템 설계 제안

현재 제공하는 '실시간 공정 품질 예측 시스템'은 가상의 공장 환경에서 운영시 발생하는 측정센서들로 획득한 데이터를 활용하기 위하여 가상데이터 저장소로 활용되는 FAST API 서버를 구축하여 저장하였다. 실시간으로 수집된 데이터는 공장의 운영 상황과 제품 품질수준을 나타내는 척도로 활용된다.


본 활용성 부문에서는 공정분석 개발을 통해 확인한 우수한 시계열 성능(MSCRED 모델)로 공정을 모니터링 하고 사전에 공정 상태를 감지 예측하여 이상유무를 사용자에게 알려주는 서비스 시스템을 제안하고자 한다.

○ SaaS 시스템 기능


시스템은 이전에 배포된 데이터를 기반으로 DB 설계 및 구축하여 학습한 모델(분류모델, 예측모델)로 향후 5회의 time-step (25초) 까지 예측하고, 품질 수준을 고/중/저 위험단계로 평가한다. 위험성 평가를 기준으로 품질 이상유무 진단해 사용자에게 위험경고를 사전에 알림으로써 제조공정상 로트(Lot)에 대한 품질정보를 제공하는 역할을 수행한다.

○ SaaS 아키텍처 세분화


- 1) FAST API 서버시스템 - 실시간 공정 데이터 수집 저장소 (데이터 수집)
- 2) 히스토리 통합 조회 - 이전에 구축된 데이터셋과 현재 수집중인 데이터를 통합하여 종합 품질정보를 제공한다.
- 3) 실시간 모니터링 - 실시간 수집되는 공정별 특성 및 모니터링 정보 제공 (품질 위험수준을 고/중/저 위험단계로 평가하여 정보 제공)
- 4) 칼럼 추세 식분 - 칼럼별 미래 예측값(5-steps)과 진행상태를 그래프로 도식화하여 추세 식분 정보 제공
- 5) 전체 데이터 보기 - 실시간으로 획득한 데이터에 대한 품질통계 정보를 확인하거나 이상이 발생한 Lot 번호에 대한 추적검사 및 품질 이상원인 정보를 제공




[사진 N] FAST API 서버 시스템 - 실시간 주조 공정 데이터 수집·저장소



[사진 N] SaaS 시스템 화면 구조 1 - 히스토리(History) 통합 조회(좌: 구축 정보 / 우: 수집 정보 통합)



[사진 N] SaaS 시스템 화면 구조 2 - 실시간 품질 정보 (좌: 공정 모니터링 / 우:추세 칼럼 분석)




[사진 N] SaaS 시스템 화면 구조 3 - 전체 데이터 정보(좌: 통합데이터 품질정보 / 우: 품질 세부정보)

○ SaaS 시스템 내부 구성

SaaS 시스템의 품질정보를 사전예측하기 위한 모델로 아래의 표 중 가장 성능이 우수한 다변량 시계열 예측모델(MSCRED (Multi-Scale Convolutional Recurrent Encoder Decoder)로 Label 정보(정상/비정상)에 대해 가중치를 두고 지도학습한 **MSCRED Label Attention** 모델이 가장 우수한 성능을 선보였다. (MSCRED: 다변량 시계열 모델로 CNN + Bi-LSTM + Attention 조합한 모델)

Model	R^2	RMSE	MAE
MSCRED_LabelAttention	0.9838	0.7528	0.4641
MSCRED_Ultimate_v2	0.9710	1.0066	0.7243
BiLSTM	0.9691	1.0394	0.7366
Simpe_LSTM	0.9668	1.0766	0.7450
MSCRED_FFT_Aware	0.9578	1.2139	0.8857
1D_CNN	0.9060	1.8136	1.3402

○ [표 3] 제안 시스템 내부모듈 구성 후보군



[사진 N] SaaS 시스템 내부 구성모델 (좌: 모델 실제 예측결과 / 우: 모델 예측성능)


□ 데이터 드리프트 관리

○ 지속성 확보를 위한 운영방안

해당 품질관리 모델은 개발 완료가 끝이 아니라, 실제 공정에 배포된 이후 지속적인 성능을 유지하는 것이 핵심이다. 특히 제조환경은 센서 노후화, 원자재 물성 변화, 계절적 요인 등으로 인하여 데이터의 통계적 특성이 변하는 데이터 드리프트가 필연적으로 발생한다. 이에, 개발된 품질 관리 시스템의 신뢰도를 장기적으로 유지하기 위해 다음과 같은 3 단계 드리프트 관리를 제안한다.

1. 모니터링 및 탐지

실시간으로 유입되는 공정 데이터를 기준데이터(초기 학습 데이터)와 주기적으로 비교하여 분포 변화를 정량적으로 모니터링 한다. 모니터링의 대상은 다음 표와 같다.




[그림] 데이터 드리프트 리포트 시각화

2. 분석 및 진단

모니터링 시스템에서 경고가 발생한 변수가 식별되면, 즉각적인 원인 분석에 착수한다.

진단	설명
시각적 진단	드리프트가 탐지된 변수의 히스토그램을 시각화하여, 분포가 어떻게 변했는 지 직관적으로 확인한다.
현업 진단	해당 변수의 변화가 의도된 것인지 현장 오퍼레이터와 확인한다.



[그림] 예시 히스토그램 분석

3. 대응 및 조치

진단결과를 바탕으로 모델의 신뢰도를 회복하기 위한 조치를 수행한다.

- 모델 재학습: 드리프트가 확인되고, 이것이 고장이 아닌 새로운 정상으로 판단될 경우, 최신 데이터를 포함하여 모델을 즉시 재학습한다.
- 데이터 보정: 센서 노후화나 고장으로 인한 비정상적인 값이라면, 해당 데이터를 이상치로 처리하고 모델을 재학습한다.

이러한 모니터링, 분석, 대응의 선순환 체계를 통해 본 시스템은 일회성 분석에 그치지 않고 변화하는 공정환경에 능동적으로 적응하며, 장기적으로 신뢰할 수 있는 사전 예측 품질관리 시스템으로 기능할 것이다.

□ 향후 연구 방향

시계열 특성과 센서 변동성을 고려하여 데이터 드리프트 (Data Drift) 감시 체계와 주기적 모델 재학습 프로세스를 향후 포함을 고려함으로써 예측 품질의 지속적인 안정성과 실무 적용성을 함께 확보하고자 한다.

□ 경진대회 만족도 조사 완료 페이지 캡처 화면

K-인공지능 제조데이터 분석 경진대회 만족도 조사

roo00747492@gmail.com [계정 전환](#)

비공개

설문에 참여해주셔서 감사합니다.

뒤로

제출

7/7페이지

양식 지우기

Google Forms를 통해 비밀번호를 제출하지 마세요.

K-인공지능 제조데이터 분석 경진대회

K-인공지능 제조데이터 분석 경진대회 만족도 조사

제조, 빅데이터, 인공지능(AI) 분야 중소 제조기업의 경쟁력 강화를 목표로 개최된 「2025년도 제5회 K-인공지능(AI) 제조데이터 분석 경진대회」에 참여해 주신 모든 분들께 감사드립니다.

본 설문은 경진대회 운영, 시스템 편의성, 문제 구성 등에 대한 만족도를 조사하여 향후 대회의 운영 방향 및 시스템 개선에 반영하고자 합니다. 귀하께서 주신 의견은 경진대회 만족도 통계 분석 및 서비스 품질 향상 목적으로만 활용될 것이며, 다른 용도로 사용하지 않을 것을 약속드립니다.

설문 참여에 진심으로 감사드립니다.

2025년 10월
KAIST 제조AI빅데이터센터

lcy6297305@gmail.com [계정 전환](#)

비공개

K-인공지능 제조데이터 분석 경진대회

K-인공지능 제조데이터 분석 경진대회 만족도 조사

응답이 기록되었습니다.

[다른 응답 제출](#)

이 문헌은 Google이 만들거나 승인하지 않았습니. - [웹식 소유자에게 문의](#) - 서비스 약관 - [개인정보처리방침](#)

양식이 의심스러운가요? [보고서](#)

Google 설문지