

데이터 분석 보고서

프로젝트 명	전력 사용량 기반 제조업 생산지수 예측 및 시각화 서비스
팀명	2조

2025. 07. 01.

담당자	PM	팀원		
	박승주	신지웅	이하연	장진혁

목 차

I. 프로젝트 개요	
1. 프로젝트 명칭 및 배경 -----	1
2. 추진 목적 및 필요성 -----	1
3. 기대 효과 -----	2
II. 데이터 수집 및 구성	
1. 데이터 수집 현황 -----	3
2. 주요 컬럼 및 구성 방식 -----	4
III. 데이터 EDA 및 특징 현황	
1. 데이터 병합 및 구조 -----	6
2. 데이터 정상성 검정 -----	9
3. 각 변수 간 상관관계 탐색 및 간단 모델링 분석 -----	13
IV. 모델링 결과 및 해석	
1. LightGBM 모델 -----	21
2. CatBoost 모델 -----	24
3. AutoML 모델 -----	28
4. HistGradientBoosting(HGB) 및 앙상블 기반 모델 -----	32
V. 웹서비스 & DB 설계 및 구축	
1. 데이터베이스 ERD 설계 -----	36
2. 데이터베이스 ERD 기반 웹 서비스 기능 정의 -----	39
3. 타겟 사용자 페르소나 및 개별 flowchart 정의 -----	40
4. 전체 flowchart 정의 -----	45

I. 프로젝트 개요

1. 프로젝트 명칭 및 배경 - 전력 사용량 기반 제조업 생산지수 예측

제조업 생산지수는 특정 시점 대비 현재 제조업의 생산 수준을 수치화한 대표적인 **경기 선행지표**로, 국가 경제의 흐름과 산업 경기의 활황 또는 침체를 진단하는 데 활용됩니다. 이 지표는 **정책 입안자, 기업 경영진, 투자 분석가 등 다양한 이해관계자**들에게 중요한 의사결정 근거로 작용.

그러나 현행 통계청 등의 발표는 **1~2개월의 시차가 존재**하며, 업종별·지역별 세부지표는 활용이 어렵다는 한계가 있습니다. 특히 산업 구조가 빠르게 변화하고 있는 현 시점에서는, **보다 빠르고 정밀한 예측 시스템**의 필요성이 대두됨.

제조업 생산지수란?

제조업 생산지수는 기준 연도(보통 2015년 = 100)를 기준으로, 현재 제조업 생산량 수준을 나타내는 지표. 매월 통계청에서 발표하며, 자동차·전자·기계·화학 등 주요 업종의 생산 흐름을 통해 **산업 전반의 경기 상황을 간접적으로 파악** 가능.

전력 사용량과의 관계

제조업은 **전력 소비가 많은 산업군**으로, 산업용 전력 사용량과 생산지수 간에는 **높은 상관관계($R=0.85\sim0.9$)**가 존재함이 다수의 연구를 통해 검증됨. 이는 전력 데이터를 기반으로 한 **제조업 생산지수 예측의 타당성**을 뒷받침.


따라서 본 프로젝트는 **전력 사용량을 핵심 선행 지표로 활용**하고, 기후·가동률·수출 등 보조 변수들을 결합하여 **지역 및 산업 수준의 생산 흐름을 예측**하는 인공지능 기반 서비스를 개발을 목표.

2. 추진 목적 및 필요성

본 프로젝트는 산업용 전력 사용량 데이터를 기반으로 제조업 생산지수를 예측하고, 예측 결과를 직관적이고 해석 가능한 형태로 가공하여 웹 서비스를 통해 제공하는 것을 목표.

이러한 시도는 다음의 관점에서 중요한 의미를 가짐.

- 선행지표 확장: 전력 사용량은 제조업 가동과 높은 상관관계를 가지며, 선제적 생산 변화 예측에 활용할 수 있는 주요 변수
- 데이터 기반 의사결정: 제조업체 경영자, 투자기관, 정책기관이 실시간 경제 흐름을 판단하고 대응하는 데 유용한 예측 지표 제공
- 공공데이터의 활용성 확대: 한전, 기상청, 통계청 등 여러 기관의 데이터를 통합 분석해 실제 활용 가능한 서비스로 가공
- 참고: 국내 논문 및 해외 보고서에 따르면, 광공업 생산지수와 산업용 전력 판매량 간 상관관계수는 0.85~0.9에 달하며, 미국 GDP와 전력소비량 간 상관관계도 90% 이상으로 보고됨.



[Figure 3] Production index of mining and manufacturing industrial, Industrial electricity usage (monthly trend)

3. 기대 효과

- **정부/정책 결정 지원:** 제조업 경기 흐름을 선제적으로 예측하여 정부 및 공공기관의 정책 결정(예: 산업 지원 정책, 지역 경제 활성화 방안)에 필요한 실질적이고 시의성 있는 참고 자료를 제공.
- **기업 경영 및 투자 의사결정 효율화:** 제조업체 관리자 및 투자자들이 예측된 생산 지수를 바탕으로 생산 계획 수립, 설비 투자 결정, 원자재 조달, 인력 운영 등 핵심 경영 의사결정의 정확성과 효율성을 높일 수 있도록 지원
- **산업 생태계의 선제적 대응력 강화:** 전력 사용량 기반의 경기 흐름 감지를 통해 제조업 전반의 이상 징후를 조기에 탐지하고, 이에 대한 선제적 대응을 가능하게 하여 산업 생태계의 리스크 관리 역량을 강화

- **데이터 기반 경제 분석 확산:** 공공 데이터와 시계열 예측, 그리고 경제적 해석을 결합한 새로운 분석 모델을 제시함으로써, 데이터 기반의 경제 분석 및 활용 사례를 확대하고 관련 분야 연구에 기여

Ⅱ. 데이터 수집 및 구성

1. 데이터 수집 현황

- 확보한 데이터 목록

범주	확보한 데이터	활용 내용
전력 사용량	계약구분별 / 월별 시군구별 전력 사용량 엑셀 (2002 ~ 2025.04)	계약구분은 산업용을 필터링 KWh 단위의 전력 사용량 추출
수출입지수	시도별 수출입지수 엑셀	지역 및 월별 수출액 필터링 (제조업 생산지수와 연관성 분석)
제조업 생산지수	지역별 제조업 생산지수 엑셀 (2002 ~ 2025.04)	예측 변수 (2020년 = 100으로 기준) 원지수 활용
제조업 평균가동률	년월별 제조업 평균가동률 엑셀	전력 사용량 - 제조업 생산지수 관계 분석 보조용 자료
평균강수량	시도별 평균강수량 엑셀	제안/분석의 해석 보완자료
평균기온	시도별 평균기온 엑셀	제안/분석의 해석 보완자료
제조업경기실사지수 (BSI)	지역별 제조업경기실사지수 (2020 ~ 2025)	추가 인사이트 확장 분석용 자료

- 출처 및 수집 방식

- 1) 한국전력공사 / 공공데이터포털
- 2) 통계청 KOSIS
- 3) 기상청 기상자료개방포털

다. 주요 변수 정리

- 1) 날짜, 지역(시), 전력 사용량, 평균 가동률, 수출액, 생산 지수, 강수량, 평균 기온
- 2) 모든 데이터는 연도 및 지역 기준으로 병합 가능하게 설계

2. 주요 컬럼 및 구성방식

본 프로젝트의 데이터는 날짜 + 지역 단위로 1차 병합되었으며, 데이터 분석 및 해석 강화 목적을 고려해 필수 / 보조 변수, 그리고 조사 중 추가적인 인사이트의 검증용인 확장 변수로 구분하여 정제 및 활용 중

컬럼명	의미	데이터 구분
month	기준 월(ex: 2024-05-01, YS)	필수 입력 변수
region	지역명 (광역 단위 기준)	필수 입력 변수
prod_index	제조업 생산지수(기준: 2020년=100)	타겟 예측값 (필수)
power_kwh	지역 및 업종별 전력 사용량(kWh 단위)	보조 입력 변수
temp_avg	지역별 평균 기온(°C)	보조 입력 변수
precipitation	지역별 평균 강수량(mm)	보조 입력 변수
export_amount	지역별 수출액(억 원/ 억 달러)	보조 입력 변수
util_rate	제조업 설비 가동률(월 단위)	보조 입력 변수
indicator	제조업 경기실사지수 항목(category)	확장 변수
value	indicator 항목 별 경기실사지수(%)	확장 변수

• 구성 방식의 결정 배경

프로젝트의 목표인 산업용 전력 사용량 및 보조 데이터들을 활용해 제조업 생산지수를 예측하는 것을 수행하기 위해 데이터 통합 전 다음의 절차를 통해 주요 변수들을 선별 및 정제

- 1) 데이터 분석 및 모델 학습에 필수로 있어야 하는 변수 → 필수 변수
- 2) 모델의 정확도 향상 및 해석력 강화를 기대할 수 있는 변수 → 보조 변수
- 3) 모델 분석 도중 추가적인 인사이트를 검증하기 위한 변수 → 확장 변수
- 4) 모델 학습 목적 또는 정책 해석 목적에 따라 분리 활용할 수 있도록 구분

• 컬럼 분류 및 활용 기준

- 1) 필수 변수 (모델링, 통계 분석, EDA의 기본 단위로 활용)

컬럼명	설명	처리 방식
month	기준 월(ex: 2024-05-01, YS)	datetime 형식(YYYY-MM-01; 월의 시작으로 설정)
region	지역명 (광역 단위 기준)	광역 시도단위, '특별시/광역시' 제거 후 정리
prod_index	제조업 생산지수 (기준: 2020년=100)	전국 단위 생산 지수 제거 후 정리 결측 데이터는 drop

2) 보조 입력 변수 (해석력 향상 및 시각적 인사이트 제공에 기여)

컬럼명	설명	처리 방식
power_kwh	지역 및 업종별 전력 사용량 (kWh 단위)	심표 제거 후 숫자형으로 사용 결측치는 선형 보간을 사용해 시계열성 유지
temp_avg	지역별 평균 기온(°C)	결측치는 평균값으로 대체
precipitation	지역별 평균 강수량(mm)	결측치는 평균값으로 대체
export_amount	지역별 수출액(억 원/ 억 달러)	심표 제거 후 숫자형으로 사용 month도 변환하여 병합 템플릿으로 통일(2025년 1월 -> 2025-01-01)
util_rate	제조업 설비 가동률(월 단위)	월별로 기록되어 있으므로 병합 시 월에 맞춰 병합

3) 확장 변수

컬럼명	설명	처리 방식
indicator	제조업 경기실사지수 항목(category)	각 항목을 카테고리 변수로 변환, 기존 데이터에 병합
value	indicator 항목 별 경기실사지수(%)	indicator와 동일하게 기존 데이터에 병합

Ⅲ. 데이터 EDA 및 특징 현황

1. 데이터 병합 및 구조

• 데이터 병합 및 전처리 기준

- 수집한 데이터를 month, region을 중심으로 하여 데이터 병합을 진행하였고, 분석 및 모델링 목적에 따라 3가지의 옵션으로 구분하여 병합 데이터 생성
- 전력 사용량은 불필요한 분류(산업용, 가정용 등)를 제외하여 '합계'만 사용
- 전국 단위 보조지표(util_rate)는 월 기준으로 병합
- 컬럼, 자료, 기간 모두 통일되어 바로 pandas 적용 가능

주요 옵션을 구분짓는 요소: *세종시 데이터*

(데이터가 2015년부터 존재 및 결측 데이터 일부 존재)

파일명	기간	세 종 포 함	결측치	특징/권장용도
option1_merged_exclude_sejong.csv	2010~2022	X	거의 없음	전국 장기 예측/시계열 EDA, 결측치 무시 가능
option2_merged_include_sejong_nan.csv	2010~2022	O	일부	세종까지 분석 가능, 결측치 실험/보간/대체
option3_merged_allregion_2015_2022.csv	2015~2022	O	소량	전국 모든 시도 동등 기간 비교, 최신 트렌드, 정책분석에 사용 가능

- option1 → 결측치 없이 곧바로 EDA, 시계열분석 및 예측 모델에 사용 가능
- option2 → 세종 포함 전체 분석, 결측치 실험·보간·대체 등 다양한 전처리 연습에 사용
- option3 → 모든 시도 동일 기간 비교/트렌드 분석, 최근 정책효과/지역별 격차 분석 등

• 병합 데이터셋 개요

1. option1_merged_exclude_sejong.csv

파일명	option1_merged_exclude_sejong.csv
기간	2010-01 ~ 2022-12 (총 13년)
지역	전국 16개 광역시·도 (세종시 제외)
주요 컬럼	month, region, power_kwh_industry, power_kwh_total, prod_index, temp_avg, precipitation, export_amount, util_rate
전력 데이터	산업용(power_kwh_industry), 합계(power_kwh_total) 모두 포함
병합 기준	month, region 기준으로 모든 데이터 inner join (공통 구간/지역만 남김, 누락 최소화)
결측치	거의 없음 (util_rate는 전국지표만 값 존재, 지역별로는 NaN)
장점	결측치 최소/모델 안정적, 장기·전국·지역별 트렌드 분석에 최적, 데이터 품질 우수
단점	세종시 분석 불가, 전국지표(util_rate) 지역별 결측 다수
권장 사용	장기 시계열 예측, 지역별/전국 패턴 분석, 제조업 생산지수/전력 연관성 분석, 표준 EDA

2a. option2_merged_include_sejong_nan + 전국.csv

파일명	option2_merged_include_sejong_nan_+전국.csv
기간	2010-01 ~ 2022-12
지역	16개 광역시·도 + 세종 + 전국
결측치	일부 (세종·전국 초기 연도 결측, 지역별 util_rate NaN)
병합 방식	left join (전체 조합 → 일부 NaN 허용)
장점	세종·전국까지 완전 포함, 전국 자체도 분석 대상에 포함 가능

단점	결측치 보간·대체 필요, 전국과 지역 간 구분 유의
권장 사용	전국 지표 포함한 비교 분석, '전국 vs 지역' 트렌드 비교

2b. option2_merged_include_sejong_nan.csv

파일명	option2_merged_include_sejong_nan.csv
기간	2010-01 ~ 2022-12
지역	16개 광역시·도 + 세종
결측치	일부 (세종 초기 연도 결측, 지역별 util_rate NaN)
장점	세종 포함, 지역 간 결측치 처리 실험 가능
단점	전국 데이터 직접 비교 불가
권장 사용	세종 포함 지역별 분석, 결측치 보간 및 대체 연습

2c. option2_merged_include_sejong_nan_clean.csv

파일명	option2_merged_include_sejong_nan_clean.csv
기간	2010-01 ~ 2022-12
지역	16개 광역시·도 + 세종
결측치	없음 (prod_index, power_kwh_industry, power_kwh_total 결측 행 drop)
장점	결측치 없는 깨끗한 데이터셋, 바로 모델링·머신러닝에 투입 가능
단점	결측치가 많은 행은 모두 제거되어 데이터 양이 줄어들 수 있음
권장 사용	결측치 없이 안정적인 예측 모델 구축, 머신러닝 학습용

3. option3_merged_allregion_2015_2022.csv

파일명	option3_merged_allregion_2015_2022.csv
기간	2015-01 ~ 2022-12
지역	16개 광역시·도 + 세종
결측치	소량 (기상·수출입 일부 결측)
병합 방식	left join (전체 조합 2015~22)
장점	동일 기간 비교(2015~22)으로 정책 분석, 지역별 격차·최신 트렌드 파악에 최적
단점	장기 추세(2010 이전) 분석 불가
권장 사용	최근 정책 효과 분석, 지역별 생산성 격차·최신 트렌드 리포트, 단기 예측·모델 시험

2. 데이터 정상성 검정

• 정상성 검정에 사용한 데이터 및 검정 결과

시계열 예측 모델링의 전처리 단계로 **option1_merged_exclude_sejong.csv** 파일 내부 7개 주요 변수에 대해 정상성 검정을 수행.

ADF 검정 및 KPSS 검정을 함께 적용해 이중 기준으로 정상성 여부를 판단.

- (1) 원시 시계열 데이터 결과: 대부분의 변수에서 ADF의 p-value > 0.05, KPSS의 p-value < 0.05로 비정상 시계열 데이터라고 판단됨.

→ 시간에 따라 평균 및 분산이 변동하는 경향 확인

- (2) 1차 차분 후 결과: 대부분의 변수에서 ADF의 p-value < 0.05, KPSS의 p-value > 0.05로 **정상성 확보**


→ 특히, power_kwh, prod_index, export_amount의 1차 차분들은 정상 시계열로 전환

- (3) 결론 및 적용

이후 시계열 모델링은 1차 차분된 변수를 기반으로 진행


정상성이 확보된 변수들만을 활용해 예측 정확도를 높일 수 있도록 설계

raw data 중 서울 지역 추출 후 시각화한 그래프




정상성 판단 기준		
ADF 검정	귀무가설(비정상성)을 기각하려면 $p\text{-value} < 0.05$	→ 두 조건을 모두 만족하면 정상 시계열
KPSS 검정	귀무가설(정상성)을 기각하지 않으려면 $p\text{-value} > 0.05$	

• 차분화 전 raw data로 정상성 검정 시각화



각 지역별 ADF 검정의 p-value를 heatmap으로 표시

색이 초록색일 수록 정상 시계열이라는 의미




각 지역별 KPSS 검정의 p-value를 heatmap으로 표시


ADF와 반대로 색이 빨간색일 수록 정상 시계열이라는 의미

- 1차 차분화 후 정상성 검정

ADF 검정



KPSS 검정



KPSS 검정에서 power_kwh_industry_diff 2곳(부산, 충남)을 제외하면 모두 1차 차분 변환을 통해 정상 시계열이 되었음을 확인할 수 있음

3. 각 변수 간 상관관계 탐색 및 간단 모델링 분석

option1에서 경기실사지수(BSI) 값을 추가한 병합 데이터를 이용하여 각 변수별 상관관계 분석을 진행

prod_index(제조업 생산지수)와 상관계수가 높은 10개의 값을 추출하여 비교

```
indicator
prod_index      1.000000
부가가치비중 (%) 0.300499
export_amount   0.230907
원자재가격현황  0.175612
util_rate       0.144990
재고전망        0.112671
재고현황        0.098490
원자재가격전망  0.073829
제품가격현황    0.061124
설비가동률현황 0.005511
Name: prod_index, dtype: float64
```

→ 부가가치비중(%), export_amount(수출금액), 원자재가격현황, util_rate(설비가동률) 등과 양의 상관관계가 존재하나 그 값이 0.2~0.3 정도로 꽤 약한 수준을 보임

• 히트맵 시각화 및 상관관계 탐색 결과

1) prod_index(제조업 생산지수)와 주요 변수의 상관관계

- prod_index vs 부가가치비중(%):
약 0.30, 약한 정도의 양의 상관관계 존재
→ 제조업 생산지수가 높아질수록 부가가치비중도 소폭 증가하는 경향을 보임
- prod_index vs export_amount(수출금액):
약 0.23. 약한 정도의 양의 상관관계 존재
→ 생산지수와 수출금액도 어느 정도 함께 움직임을 의미
- prod_index vs 원자재가격현황, util_rate 등:
0.10~0.17 수준의 미약한 양의 상관관계

2) BSI(경기실사지수) 내 주요 심리지표들끼리

- 예: 매출액현황, 국내시장출하현황, 수출현황, 제품가격현황 등

서로 0.4~0.5까지 비교적 높은 상관관계를 가짐

→ 제조업 경기 '심리' 지표들은 실제로 동조현상 존재

3) 전력데이터/실물경제 변수와의 관계


- 산업용 전력사용량/전체 전력사용량 등은 prod_index와 약 0.1~0.2 수준의 미약한 양의 상관관계.
- util_rate(설비가동률)와 prod_index도 0.1~0.15 내외로 '약한' 양의 상관관계.

4) 부가가치비중(%)와 다른 변수들

- prod_index, util_rate, export_amount 등 실물 변수들과 0.2~0.3 정도 양의 상관관계.
- 심리지표와는 비교적 낮은 상관.

• 전반적인 결론

- prod_index(제조업 생산지수)는 경기심리(BSI)와 실물 변수 모두와 약한 양의 상관관계를 가짐
→ 그러나 상관계수 자체가 아주 높지는 않아, '참고 변수'로는 유용하나 단일 변수로 예측하기엔 한계 존재
- 심리지표들(매출액, 출하, 시황, 수출 등)은 서로 강하게 연결
→ 예측모델에서 '심리지표 묶음'은 의미 있음
- 전력, 설비가동률 등 실물 지표는 생산지수와 느슨하게 연결
→ 실제 생산과 소비가 어느 정도 연동되어 있지만, 1:1로 동작하진 않음



• 각 지역별 상관계수 탐색

지역별로 prod_index와 어떤 변수/지표가 연관이 큰지 탐색 작업 진행

지역	Top1	Top2	Top3	Top4	Top5
강원	원자재가격현황 (0.18)	설비가동률전망 (0.17)	부가가치비중 (%) (0.17)	제품가격현황 (0.10)	원자재가격전망 (0.08)
경기	부가가치비중 (%) (0.59)	수출전망 (0.20)	export_amount (0.20)	util_rate (0.19)	경상이익전망 (0.11)
경남	고용현황 (0.51)	재고전망 (0.47)	경상이익현황 (0.47)	설비가동률현황 (0.35)	경상이익전망 (0.26)

경북	util_rate (0.62)	시황현황 (0.42)	제 품 가 격 현 황 (0.41)	설비가동률현황 (0.37)	국내시장출하현황 (0.32)
광주	원자재가격현황 (0.27)	util_rate (0.14)	설비가동률전망 (0.03)	재고현황 (0.03)	원자재가격전망 (0.03)
대구	국내시장출하현황 (0.53)	제 품 가 격 현 황 (0.51)	자 금 사 정 현 황 (0.50)	매 출 액 현 황 (0.49)	시황현황 (0.48)
대전	설비가동률현황 (0.44)	수출현황 (0.40)	util_rate (0.38)	자 금 사 정 현 황 (0.35)	설 비 투 자 현 황 (0.20)
부산	원자재가격현황 (0.56)	설비가동률현황 (0.55)	제 품 가 격 현 황 (0.52)	국내시장출하현황 (0.40)	제 품 가 격 전 망 (0.37)
서울	자 금 사 정 현 황 (0.56)	재고전망 (0.52)	시황현황 (0.50)	재고현황 (0.46)	매 출 액 현 황 (0.44)
울산	재고현황 (0.25)	자 금 사 정 현 황 (0.24)	원자재가격현황 (0.19)	수출전망 (0.19)	util_rate (0.17)
인천	부 가 가 치 비 중 (%) (0.60)	자 금 사 정 현 황 (0.18)	재고현황 (0.13)	경 상 이 익 현 황 (0.06)	경 상 이 익 전 망 (0.05)
전남	util_rate (0.52)	부 가 가 치 비 중 (%) (0.44)	재고현황 (0.24)	원자재가격현황 (0.22)	수출현황 (0.21)
전북	원자재가격현황 (0.66)	설 비 투 자 현 황 (0.62)	고용전망 (0.60)	시황전망 (0.54)	경 상 이 익 전 망 (0.53)
충남	util_rate (0.50)	원자재가격현황 (0.46)	제 품 가 격 현 황 (0.34)	경 상 이 익 현 황 (0.31)	국내시장출하현황 (0.28)

• 상관계수 탐색 결론

- 지역별로 prod_index와 강하게 연결되는 변수가 상이
 - 경북, 충남, 전남 등에서는 설비가동률(util_rate), 경남/대구 등은 고용, 자금사정, 재고와도 연결
 - 경기/인천 등은 부가가치비중(%)이 매우 높음
- export_amount(수출금액), 원자재가격현황등은 여러 지역에서 0.2~0.5 수준의 의미 있는 상관계수
- 실제로 전국 단위나 월별 분석보다 지역별 분석에서 더 뚜렷한 패턴이 보임
- 즉, 모델링·인사이트 도출 시에는 반드시 지역별로 주요변수를 다르게 반영해야 더 정확한 결과와 해석이 가능

• 간단 예측 모델링 및 결과

구분	내용
데이터 기간/규모	2015~2025년, 17개 시도, 월별
주요 입력 변수	export_amount(수출금액), 매출액현황, power_kwh_industry(전력), 원자재가격현황, 재고현황, util_rate(설비가동률), 부가가치비중(%), region_code(지역)
예측 대상	prod_index (제조업 생산지수)
모델	XGBoostRegressor (회귀 모델)
성능 지표	RMSE: 12.38 MAE: 9.48 R ² : -1.05 (설명력 매우 낮음, 예측 불가)
변수 중요도 순위	1) export_amount 2) 매출액현황 3) power_kwh_industry 4) 원자재가격현황 5) 재고현황 6) util_rate 7) 부가가치비중(%) 8) region_code
핵심 해석	여러 변수 조합에도 불구하고 모델의 설명력(R ²)이 음수로 나타나 예측력 및 실무 적용성 없음 →데이터 구조/변수 선택 보완 필요

모델 평가


```
rmse = mean_squared_error(y_test, y_pred) ** 0.5
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
print(f"RMSE: {rmse:.2f}, MAE: {mae:.2f}, R2: {r2:.4f}")
```

59]

✓ 0.0s

RMSE: 12.38, MAE: 9.48, R²: -1.0487

주요 변수별 중요도(Feature Importance)



• 간단 모델링 결과 해석 및 인사이트

- 모든 주요 변수 조합에도 불구하고, 모델의 R^2 가 음수(-1.05)로 나타나 예측력 없음
- 즉, 수출금액, 전력, 매출, 원자재, 재고, 설비가동률 등 실물·심리지표의 조합만으로는 제조업 생산지수의 실제 변동성을 설명·예측하기 어려움
- 데이터 구조(피벗/결측/타깃값 일관성 등) 보완, 지역·기간별 분석 또는 변수 추가 필요

→ 인사이트: "해당 변수 조합 및 데이터 구조로는 제조업 생산지수 예측이 실질적으로 불가능하며, 실무적/정책적 활용을 위해서는 데이터 구조·변수 선택·지역/시점별 세분화 등의 추가 보완이 반드시 필요함."

• 확장 변수(BSI) 포함 시 결과 비교

제조업 실물경기를 대표하는 생산지수(prod_index)를 예측하기 위해 설계된 두 가지 머신러닝 모델의 성능을 비교한 결과를 정리한 문단이다. 각 모델은 동일한 목적을 갖되, 입력 데이터의

구조와 변수 구성, 시계열 처리 방식에서 중요한 차이를 보이며, 이러한 구조적 차이가 모델 성능에 어떤 영향을 미쳤는지를 중심으로 분석하였다.

첫 번째 모델(option1_with_bsi_long.csv 기반)은 경기실사지수(BSI)를 포함한 다양한 심리지표와 일부 실물지표를 포함하고 있으며, 데이터는 long-format 구조로 되어 있다. 즉, 하나의 시점과 지역에 대해 여러 개의 indicator와 value 조합이 각각 별도 행으로 존재한다. 이 방식은 데이터의 확장성은 높지만, 변수 간 종속성이나 시계열 구조를 반영하기 어렵다는 단점이 있다.


반면 두 번째 모델(option3_with_bsi_2015_2025.csv 기반)은 핵심 실물변수(전력사용량, 수출, 설비가동률 등)를 중심으로 wide-format 데이터에 시계열 lag 구조를 적용하였다. 특히 각 변수에 대해 전월 데이터를 반영함으로써 제조업 생산지수의 실제 변동에 영향을 주는 선행 요인을 모델에 반영하고자 하였다.

항목	Option1	Option3
데이터 구조	Long format (indicator별 행 분리)	Wide format + 일부 long 구조 병합
시계열 lag 변수 적용	적용되지 않음	Lag1 중심으로 적용 (power, export 등)
입력 변수 수	10개 이상, BSI 지표 다수 포함	3~4개 (power, export, util_rate 등 핵심 변수)
주요 변수 유형	심리지표(BSI) 중심, 실물지표 혼합	실물지표 중심, 일부 심리지표 포함
모델 성능 (R^2)	-1.05(설명력 없음)	0.23(부분 설명 가능)
오차 (RMSE / MAE)	12.38 / 9.48	14.06 / 10.12
최상위 Feature Importance	export_amount, 매출액현황, 전력	전월 전력, 전월 수출, 전월 설비가동률
정책 반응 고려	없음	가능 (시점 반응 분석 포함)
실무 적용성	낮음	높음 (경향성 탐지에 유리)
모델	XGBoostRegressor (회귀 모델)	

• 모델 성능 비교 및 평가

모델 성능 지표(R^2 , RMSE, MAE)를 기준으로 평가한 결과, option1 기반 모델은 R^2 가 **-1.05**로 나타나 타깃 변수의 분산을 전혀 설명하지 못하는 수준이었으며, 실무적으로도 예측 기능을 수행할 수 없는 모델로 판단된다. 반면 option3 기반 모델은 $R^2 = 0.23$ 으로 단순 변수 조합에도 불구하고 일정 수준의 설명력을 확보하였으며, 예측 오차(RMSE: 14.06, MAE: 10.12)는 실무적 활용이 가능한 범위로 나타났다.

또한 변수 중요도 분석 결과, option1 모델에서는 수출금액, 매출현황 등 BSI 중심 변수가 상위에 위치했지만, 이들은 정량성과 일관성이 떨어져 모델 성능에 크게 기여하지 못했다. 반면 option3 모델에서는 전월 전력사용량이 가장 중요한 변수로 도출되었으며, 이는 실물 산업활동의 직접적인 반영이라는 점에서 예측 타당성이 높다.



• 결과 해석 및 시사점

모델 성능의 차이는 단순히 입력 변수의 수나 모델링 기법보다도 **데이터 구조와 시계열 처리 방식의 적절성**에 따라 좌우되었음을 확인할 수 있다. 특히 심리지표(BSI)는 경기 체감이나 기대를 나타내는 성격이 강해 실제 생산 실적과는 분리된 움직임을 보일 수 있으며, 단독 예측변수로 활용하기엔 한계가 존재한다. 따라서 이들은 **보조지표로만 활용**하고, 예측에는 **실물 중심의 변수(전력, 수출, 설비 등)를 활용**하는 것이 보다 효과적이다.

또한 option3 모델에서 확인된 바와 같이, 단지 '현재 시점'의 값만을 사용하는 것이 아닌, **전월 기준의 시계열 lag 변수**를 도입하는 방식이 예측 성능 향상에 유의미한 효과를 준다는 점도 주요한 인사이트다.

- 결론 및 추천 방향

- 심리지표 중심 모델은 설명력 부족으로 예측에 부적합
→ 직관적 해석은 가능하나, 실적 반영력은 낮음
- 실물지표 + lag 처리된 모델이 예측력 우수
→ 단기 생산 동향 감지 및 정책 반응 진단에 유리
- 모델 설계 시 핵심 고려사항
 - 전력·수출 등 실물 중심 변수 확보
 - 데이터 구조 통일 (wide-format)
 - 시계열 lag 변수 적용
 - 정책 이벤트 반응을 위한 dummy 변수 고려

향후 유사한 산업 예측 모델 설계 시, 본 분석 결과를 참고하여 **데이터 구조 설계 및 변수 선택 기준**을 보다 전략적으로 접근하는 것이 필요하다.

IV. 모델링 결과 및 해석

1. LightGBM 모델

산업 전력 소비량의 연간 합계 지표인 Yearly_Prod_Index를 예측하고, 이를 통해 미래 산업 활동 및 경기 흐름을 추정. 다양한 전력량 관련 데이터, 온도, 경제 지표 데이터를 통합하고, 고급 시계열 특성 공학 및 앙상블 기법을 활용하여 예측 성능(R^2)을 지속적으로 개선하는 것을 목표.

LightGBM을 선택한 이유: 앞서 진행한 간단 모델링의 경우 XGBoost 모델을 사용하였는데, LightGBM 모델은 XGBoost와 비교하여 일반적으로 더 빠른 학습을 보여주면서 비슷하거나 더 나은 성능을 보여주기 때문에 성능을 비교하기 위해 LightGBM 모델로 결과를 확인

- 데이터 개요

항목	내용
데이터명	option2_merged_include_sejong_nan_clean 테이블 (주요 전력량) Excel: trimmed_temperature_data.xlsx (온도) Excel: BSI.xlsx (BSI) Excel: CIBI.xlsx (CIBI) Excel: HOME 발전·판매_판매전력량_월별.xlsx (월별 판매전력량)
기간	파일별 상이 (주로 2010년~2025년 범위의 월별 데이터)
구조	MySQL 데이터: month, region, power_kwh_total 등 '긴' 형태의 월별/지역별 지표 Excel 데이터 (온도, BSI, CIBI, 월별 판매전력량): '연도'와 '1월'~'12월' 컬럼으로 구성된 피벗(Wide) 형태
전처리	데이터 타입 변환: power_kwh_total 등 숫자형 컬럼 object → float 변환 날짜/연월 추출: month 컬럼을 datetime으로 변환 후 Year, Month 추출 월별 집계: 지역별 데이터(region)를 연월 기준으로 집계 데이터 통합: 모든 데이터를 Year와 Month를 기준으로 outer merge
데이터 변경 이유	초기 option1 테이블은 성능이 저조하여 option2_merged_include_sejong_nan_clean으로 변경 option3 테이블은 기간 문제 및 데이터 특성상 오히려 성능이 하락하여 option2_merged_include_sejong_nan_clean으로 회귀 HOME_발전·판매_판매전력량_월별.xlsx는 새로운 월별 전력량 정보를 제공하여 추가

- 데이터 전처리

• 데이터 타입 변환:

- month컬럼을 datetime으로 변환 후 Year, Month파생 변수 생성
- power_kwh_total, power_kwh_industry, prod_index, temp_avg, precipitation, export_amount, util_rate등 MySQL에서 로드된 주요 수치형 컬럼을 object에서 float으로 변환 (errors='coerce'로 변환 불가 값은 NaN처리)

• 결측치 처리:

- 수치형 특성 컬럼의 NaN값은 0으로 일괄 처리
- 타겟 변수(Yearly_Power_Index)의 NaN값을 포함하는 행은 제거
- Date_Pseudo컬럼의 NaN값을 포함하는 행은 제거

• 고급 특성 공학:

◆ 지연 특성(Lag Features):

- 주요 월별 특성(power_kwh_total, power_kwh_industry, util_rate, prod_index, temp_avg, Monthly_Temperature_Excel, Monthly_BSI, Monthly_CIBI, Monthly_Sales_Elec)에 대해 **1, 2, 3, 6, 9, 12, 24개월 전 값**을 새로운 특성으로 추가
- 타겟 변수 **Yearly_Power_Index**의 **1년 전, 2년 전 값**을 특성으로 추가 (Yearly_Power_Index_lag_1Y, _lag_2Y)

◆ 이동 평균(Rolling Mean) 특성:

- 주요 월별 특성(power_kwh_total, util_rate, temp_avg, Monthly_Temperature_Excel, Monthly_BSI, Monthly_CIBI, Monthly_Sales_Elec)에 대해 **3개월, 6개월, 12개월 이동 평균**을 새로운 특성으로 추가

◆ 시간 기반 파생 변수: Date_Pseudo를 생성하여 DayofWeek_Pseudo, WeekofYear_Pseudo, Quarter특성 추가

• 스케일링:

- 모든 수치형 특성(X)과 타겟 변수(y)에 StandardScaler를 적용하여 표준화



- 모델 구성

항목	내용
사용 모델	앙상블 모델 (VotingRegressor): LightGBM Regressor- Ridge Regressor- ElasticNet Regressor
타겟 변수	Yearly_Power_Index (MySQL power_kwh_total의 연간 합계)
데이터 분리	train/test (80:20), 시간 순서 유지 (최신 데이터를 테스트셋으로 사용)
하이퍼파라미터 튜닝	방법: RandomizedSearchCV 모델: LightGBM Regressor 탐색 파라미터: n_estimators, learning_rate, num_leaves, max_depth, subsample, colsample_bytree, reg_alpha, reg_lambda 교차 검증: TimeSeriesSplit (n_splits=5) 탐색 횟수: n_iter=50

- 모델 성능 평가

지표	값	해석
RMSE	1,792,622.9481 (약 179만)	예측 오차의 표준편차. 이전 수백억 단위에서 대폭 개선되어 실용적인 오차 스케일로 진입
MAE	1,394,438.7039 (약 139만)	평균 절대 오차 RMSE와 유사하게 오차 스케일이 크게 줄었음
R ²	0.1024 (10.24%)	예측 설명력. 이전 최고값(0.0549)을 넘어 가장 높은 R ² 달성. 모델이 타겟 변동성의 10%를 설명하기 시작함

- 예측 결과 시각화 및 요약



- **전체 흐름:** 모델의 예측선(빨간색 점선)이 실제 값(파란색 실선)의 전반적인 추세와 주요 등락을 이전보다 훨씬 더 유사하게 따라가는 양상을 띤. 이전처럼 평평하게 예측하는 경향이 크게 감소
- **예측 민감도:** 실제 값의 급격한 피크나 하락 지점을 완벽하게 포착하지는 못하고 다소 완만하게 예측하는 경향은 여전히 있으나, 패턴을 파악하는 능력이 크게 향상
- **외삽 영역:** 그래프 후반부(훈련 데이터 범위를 벗어나는 미래 예측 구간으로 추정)에서는 여전히 실제 값과의 오차가 커지는 경향. 이는 앙상블 기법에도 불구하고 트리 기반 모델의 외삽 한계가 완전히 해결되지 않았음을 시사

- LightGBM 모델 결론

- **모델 적합도:** 이전 모델들에 비해 R^2 값이 10%를 넘어서고 RMSE/MAE 스케일이 정상화되는 등 상당한 성능 개선 달성. 모델이 Yearly_Power_Index의 패턴을 학습하고 예측하기 시작했음을 의미하지만 여전히 예측 설명력(10%)은 실무 적용을 위해 더 높은 수준(예: 50% 이상)까지 올려야 할 필요 있음
- **과적합 여부:** RandomizedSearchCV와 TimeSeriesSplit, early_stopping을 통해 과적합 가능성을 제어하려 노력했으며, 테스트셋 성능이 양수로 나오면서 안정적인 학습을 보임
- **개선 여지:** 외삽 능력 부족 및 경제 지표의 낮은 중요도가 여전히 개선이 필요한 영역

2. CatBoost 모델

산업 생산지수(prod_index)를 주요 경제 지표 기반으로 예측

데이터가 지역별로 나누어져 있는 만큼, 지역별로 카테고리 번호를 부여해 범주형 변수에 강하다고 알려진 CatBoost 모델을 사용하여 예측 모델 향상(주로 R^2) 기대

CatBoost 채택 이유: 크게 5가지 요인으로 인해 CatBoost 모델을 고려

구분	내용	이유
데이터 구조	현재 데이터는 시계열처럼 시간 흐름은 있으나, 완전한 시계열(Time Series) 구조는 아님	날짜별 연속성이 불완전 결측 많고, 주기성/계절성도 미약
예측 목표	"미래 시점의 단일 생산지수" 또는 "외부 변수(전력사용량 등)에 따른 변화량"	순수한 시계열 예측보다 회귀 문제에 가까움
피처 다양성	단순히 날짜 외에도 업종, 지역, 전력 사용량 등 다차원 변수포함	시계열 모델은 이질적 피처 다루기 어려움 반면 CatBoost는 범주형+수치형 조합에 강함
해석력 중요	어떤 요인이 생산지수에 영향을 주는지가 중요	CatBoost는 Feature Importance 제공
데이터 양 & 품질	시계열 모델은 데이터 연속성+양이 중요	우리는 월별 수준의 비교적 적은 데이터 → 트리 기반이 유리

결론) 전통적인 시계열 모델을 고려하였으나, 우리의 데이터 특성과 분석 목적이 시계열보다 범주형/수치형 다변량 회귀에 가까웠기 때문에 CatBoost를 추가로 진행.

- 데이터 개요

항목	내용
데이터명	option1_with_bsi_long.csv
기간	2020년~2025년 범위의 월별 데이터
구조	month, region, power_kwh_industry, power_kwh_total, prod_index, temp_avg, precipitation, export_amount, util_rate, indicator, value, region_code
전처리	데이터 타입 변환: power_kwh_total, power_kwh_industry 숫자형 컬럼 object → float 변환 month: object → datetime 변환 region: 지역을 숫자형 label로 변환(df['region'].cat.code → 0번부터 지역 개수만큼 번호 부여(예: 강원 = 0, 경기 = 1, ...)후 region_code로 정의

- 데이터 전처리

- 학습에 사용할 feature, target 변수 특징
 - feature: power_kwh_industry{lag 0~3}, export_amount{lag 0~3}, util_rate{lag 0~3}, region_code
 - target: prod_index
 - feature와 target만을 필터링 후 결측값이 있으면 제거(dropna())
- 지연 특성(Lag features)
 - 주요 feature에 대해 0~3개월 전 값을 lag 변수로 추가 {lag0 ~ lag3}
- 피쳐 스케일링(Scaling)
 - 모든 feature들에 대해 MinMaxScaler() 적용하여 스케일링 진행



- 모델 구성



항목	내용
모델	CatBoostRegressor
타겟 변수	prod_index
입력 변수	power_kwh_industry{lag 0~3}, export_amount{lag 0~3}, util_rate{lag 0~3}, region_code
데이터 분리	train/test (80:20), 시간 순서 유지

- 모델 성능 평가 및 시각화

지연값	지표	값	해석
lag 0	RMSE	181.35	예측 오차 표준편차
	MAE	9.46	평균 절대 오차
	R ²	0.3240	예측 설명력 (32.08%)
lag 1	RMSE	184.28	예측 오차 표준편차
	MAE	9.47	평균 절대 오차
	R ²	0.3276	예측 설명력 (32.76%)
lag 2	RMSE	172.30	예측 오차 표준편차
	MAE	9.13	평균 절대 오차
	R ²	0.3883	예측 설명력 (38.83%)
lag 3	RMSE	152.76	예측 오차 표준편차
	MAE	8.93	평균 절대 오차
	R ²	0.4358	예측 설명력 (43.58%)

전체 결과 요약: 입력 데이터의 time lag를 많이 줄 수록 모델의 설명력(R²)이 증가하는 경향. 하지만 전체적인 설명력 값의 크기 자체는 많이 낮음 (0.5 미만)





항목	해석
전체 흐름	실제와 예측의 등락 곡선 형태만 유사함(값은 큰 차이 있음)
예측 민감도	급등락 반응은 약하나 lag가 높을수록 급등락이 잘 반영됨
활용성	산업 정책용 흐름 예측 정도에는 적합

- 결과 분석

CatBoost 모델을 사용하여 결과를 분석해보았을 때, 이전 진행한 XGBRegressor와 큰 차이를 보이지 않음

→ CatBoost 모델이 category 변수를 반영을 잘 못하나?

→ 조사해본 결과 CatBoost 모델이 강점을 보이는 분야는 현재 데이터처럼 feature 중 일부(1~3개)만 category 변수인 경우 보다는 **거의 모든 feature가 category일 때**

현재 데이터와 같은 경우, XGB 또는 lightGBM보다 더 느린 학습 시간을 보여준다고 함

→ 단일 CatBoost 모델은 적합하지 않음

→ CatBoost를 사용하려면 카테고리 변수를 더 추가하고 학습 진행해야 할 것으로 보임

3. AutoML 모델

산업 생산지수(prod_index)를 주요 경제 지표 기반으로 예측

PyCaret, H2O AutoML 기법을 활용하여 $R^2 > 0.5$ 이상의 모델 발굴하기

AutoML 모델 채택 이유:

1. 모델 개발 자동화

- 데이터 전처리, 특징 선택, 알고리즘 선택, 하이퍼파라미터 튜닝등을 자동으로 수행.
- 머신러닝 파이프라인 전체를 자동화함으로써 복잡한 수작업을 간소화.

2. 시간과 자원 절약

- 반복적 작업 및 튜닝 과정에서 큰 효율성 제공 가능

3. 성능 최적화

- 자동화된 하이퍼파라미터 탐색, 앙상블 모델 등을 통해 경쟁력 있는 성능의 모델을 쉽게 획득 가능.
- 더 넓은 탐색 공간을 더 빠르게 탐색 가능

-데이터 개요

항목	내용
데이터명	option1_merged_exclude_sejong.csv
기간	2002 ~ 2025년
구조	지역별 산업지표
전처리	전처리 3 영역 확인 → 전력량 lag 변수 생성

- 데이터 선택 변경 이유

option1_with_bsi_long.csv 결과 성능이 오히려 감소 (R2값 H2O 결과 0.32 PyCaret 결과 -0.07)

1) Noise 증가 → 모델이 잘못된 패턴을 학습

- 의미 없는 변수(예: 랜덤 숫자, 상수처럼 거의 안 바뀌는 컬럼)가 많으면,
- AutoML이 거기에서 "쓸데없는 규칙"을 찾으려고 하면서 오히려 성능이 저하됨.

2) 차원의 저주(Curse of Dimensionality)

- feature(컬럼) 수가 늘어나면, 데이터가 고차원 공간에 흩어져 밀도가 희박해짐.
- 실제로 유효한 예측을 하기 위해 더 많은 데이터가 필요하게 됨.

- (보통 feature 수가 2배가 되면 필요한 데이터 수는 기하급수적으로 증가)

3) 자동 탐색 (Feature Selection/Hyperparameter Tuning) 시간이 늘어남

- AutoML은 다양한 변수 조합을 사용하면서 모델을 탐색
- feature가 너무 많으면 탐색 공간이 너무 커져서 최적 조합을 못 찾고 제한된 시간 내에 sub-optimal (덜 좋은) 모델을 선택할 수 있음.

- 데이터 전처리

- **데이터 타입 변환**
 - power_kwh_industry, power_kwh_total: object → float 변환
(ex: pd.to_numeric(errors='coerce'))
 - month → datetime 변환
 - 결측치는 dropna로 제거
- **범주형 인코딩 (선택)**
 - region: Pycaret, H2O AutoML 자체 One-Hot Encoding 또는 impact encoding 처리 하기에 제외
- **스케일링 (선택)**
 - Pycaret, H2O AutoML 자체 내부적으로 스케일링을 어느 정도 처리하기에 제외

- 모델 구성

알고리즘	항목	내용
Pycaret	모델	K Neighbors Regressor
	타깃 변수	prod_index
	데이터 분리	train/test (80:20), 시간 순서 유지
H2O	모델	Ensemble model, GBM, XGBoost Regressor (정확도 순서로 나열)
	타깃 변수	prod_index
	데이터 분리	train/test (80:20), 시간 순서 유지

- H2O 알고리즘의 각 모델별 결과

	model_id	rmse	mse	mae	rmsle	mean_residual_deviance
	GBM_4_AutoML_11_20250630_43609	10.729	115.112	7.98685	0.0920672	115.112
	GBM_2_AutoML_11_20250630_43609	10.7783	116.171	7.92265	0.0925122	116.171
	GBM_grid_1_AutoML_11_20250630_43609_model_1	10.783	116.273	8.01205	0.0926327	116.273
	GLM_1_AutoML_11_20250630_43609	10.8275	117.235	8.1426	0.0931039	117.235
	GBM_3_AutoML_11_20250630_43609	10.8296	117.281	8.046	0.0930356	117.281
	GBM_grid_1_AutoML_11_20250630_43609_model_2	10.942	119.728	8.20158	0.0938436	119.728
	XGBoost_grid_1_AutoML_11_20250630_43609_model_4	10.9477	119.852	8.3698	0.0938543	119.852
	GBM_5_AutoML_11_20250630_43609	11.05	122.103	8.19742	0.0946978	122.103
	DeepLearning_grid_2_AutoML_11_20250630_43609_model_1	11.3233	128.218	8.40224	0.0976058	128.218
	XRT_1_AutoML_11_20250630_43609	11.4596	131.322	8.71727	0.0985901	131.322

- 모델 성능 평가(테스트셋 기준)

1) pycaret

총 19개 모델(knn, omp, ridge, lasso, xgboost, rf, lightgbm, ada 등) 중 knn을 채택

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE
0	K Neighbors Regressor	17.4555	563.1888	23.7316	0.1032	0.3257	0.2708

지표	값	해석
RMSE	23.73	예측 오차 표준편차
MAE	17.45	평균 절대 오차
R ²	0.1032	예측 설명력 (10.3%)

2) H2O

```


MetricsRegression: gbm
Reported on test data. **

92.24460597409117
9.60440555027177
6.800363331840216
E: 0.08022158139771998
Residual Deviance: 92.24460597409117
0.30785918712910565
  
```



지표	값	해석
RMSE	23.73	예측 오차 표준편차
MAE	17.45	평균 절대 오차
R ²	0.1032	예측 설명력 (10.3%)

- 모델 시각화 및 결과 요약

1) pycaret



2) H20



항목	해석
전체 흐름	실제값과 유사한 패턴 유지하지 못함
예측 민감도	급등락 반응은 약함 (평균 회귀 경향)
활용성	산업 정책용 흐름 예측에는 적합

- 모델 결과 분석 및 해결 과제

항목	내용
모델 적합도	예측력 충족하지 못함
과적합 여부	테스트셋 기준 안정적이지 못함, 과적합 없음
개선 여지	극단값 대응 위한 이벤트 변수 추가 고려

• 향후 과제

1) LightGBM 등 다른 트리 기반 알고리즘 추가

- 현재 PyCaret과 H2O AutoML 결과에서 GBM / XGBoost가 상대적으로 양호
→ 직접 **LightGBM, CatBoost**등으로 튜닝(파라미터 조정 포함)하여 성능 개선 시도

2) Feature Selection

- 현재 feature가 많거나 의미가 약한 컬럼 포함
→ **Feature Importance**, Correlation Heatmap, VIF 등을 통해 불필요 컬럼 제거
→ Noise 감소 및 성능 개선 기대.

3) 시계열 Feature 추가 및 AutoRegressive 고려

- 산업생산지수(prod_index)는 시계열 성격이 강함.
→ **lag(1), lag(2), moving average, diff**등 시계열 파생변수를 추가하고 AR(X), Prophet 같은 시계열 모델과 비교.

4. HistGradientBoosting(HGB) 및 앙상블 기반 모델

예측하려는 변수인 prod_index는 경가지표이기 때문에, 예측을 하려고 할 땐 feature들 간에 복잡한 상호관계가 있을 것으로 가정
→ 기존에 확인하였던 XGBoost 또는 RF 모델에 비해 sklearn pipeline에서 메모리를 효율적으로 사용할 수 있는 비선형 boosting 모델인 HistGradientBoosting 모델을 포함한 앙상블 모델을 채택, 여러 모델의 앙상블을 통해 각 단일 모델의 학습을 보완하면서 예측력 향상을 기대하여 모델을 구상

• HistGradientBoosting 모델의 특징

1. 훨씬 빠른 학습 속도

- 연속형 특성(숫자 데이터)을 **히스토그램(bin)**으로 변환하여 계산
- 이산화된 값 덕분에 **분할점 후보 수가 줄어들어 계산량이 크게 감소**
- 대용량 데이터에서도 **빠르게 학습**할 수 있어 XGBoost/LightGBM과 유사한 수준의 속도를 제공

2. 더 적은 메모리 사용

- 모든 데이터를 float 상태로 저장하지 않고 **bin index**로 처리하기 때문에 메모리 사

용량이 적고 특히 대규모 데이터셋에 유리

3. 카테고리형 변수 및 결측치 자동 처리

- categorical타입을 지정하면, 원-핫 인코딩 없이 **자동으로 최적 분할**을 수행해 고차원 카테고리형 변수에도 효과적
- 결측값을 자동으로 **좌/우 서브트리 중 하나로 보내는 방식으로 처리**하여 별도의 처리 과정 없이 결측치 전처리 불필요

- 데이터 및 변수 개요

분석 데이터: option1_merged_exclude_sejong.csv

- 주요 목표 변수: prod_index(산업 생산지수)
- 설명 변수:
 - 환경 데이터: power_kwh_industry, power_kwh_total, temp_avg, precipitation, export_amount, util_rate
 - 시계열 지표: lag(1,2), rolling mean(3) 포함

- 모델링 및 검증 방법

- 시계열 특성을 반영하기 위해 **TimeSeriesSplit(3분할 CV)** 사용
- 누락값은 SimpleImputer(mean)으로 처리
- 모델 리스트
 - Ridge Regression
 - XGBoost Regressor
 - RandomForest Regressor
 - HistGradientBoosting Regressor (GridSearchCV로 하이퍼파라미터 튜닝)
 - 앙상블(가중평균): $Ens = 0.2 \times \text{Ridge} + 0.2 \times \text{XGB} + 0.2 \times \text{RF} + 0.4 \times \text{HGB}$


- 모델 성능 평가 (Test set 기준)

모델	R ²	RMSE	MPE
Ridge	0.5712	8.0246	-0.3006%
XGB	0.5462	8.2558	-0.5438%
RF	0.5331	8.3740	-0.5162%
HGB	0.6205	7.5492	-0.3861%
Ens	0.6332	7.4215	-0.4266%

→ 전반적으로 앙상블(Ens) 모델이 가장 우수한 성능($R^2=0.63$, $RMSE=7.42$)을 보임.

- 예측 결과 시각화

- 실제 vs 예측 scatter plot을 통해 모델별 예측 정확성을 비교
- 대각선(붉은 점선)에 가까울수록 이상적



→ 앙상블과 HGB 모델에서 대체로 대각선에 가까운 분포를 보이며, Ridge, XGB, RF는 상대적으로 분산이 더 큰 모습을 보여줌

- 모델 예측 결론 및 향후 방향

HistGradientBoosting + Ensemble이 가장 높은 예측력을 보임.

- R^2 : 약 0.63 → 실제 변동의 63% 설명
- RMSE: 약 7.4 → 평균적으로 ± 7.4 단위 오차 발생

추후 보완 방안

- Feature Selection/Engineering (상관성이 낮거나 multicollinearity 높은 변수 제거 혹은 추가 lag, rolling)
- Cross Validation 스플릿 수 증가
- LightGBM, CatBoost 등 추가 앙상블 검토

5. 최종 모델 결과 비교

구분	모델명	R^2 (예측 설명력)	RMSE	비고
단일 모델	Ridge Regression	0.5712	8.02	기본 선형 모델, 베이스라인
단일 모델	XGBoost Regressor	0.5462	8.26	예측력은 양호하나 과적합 우려
단일 모델	Random Forest	0.5331	8.37	분산 큼, 예측 안정성 다소 부족
단일 모델	HistGradientBoosting	0.6205	7.55	가장 강력한 단일 모델

앙상블	Ens (가중 평균)	0.6332	7.42	최종 성능 최고, HGB 기반 가중치
단일 모델	CatBoost Regressor	0.43~0.32	152~184	범주형 반영 미비, 지역 변수만 사용
AutoML	PyCaret	0.10	23.73	설명력 부족, 평균 회귀 경향
AutoML	H2O AutoML	0.31	9.60	CatBoost보다 나은 성능, 실용성 부족
단일 모델	XGBoost (정상성 기반)	0.4840	11.89	안정성 확보, 비교적 낮은 성능
연간 예측	LightGBM 앙상블	0.1024	약 1.79M	타겟 지표가 다름 (Yearly Power Index)

결론 및 요약

- **가장 높은 성능($R^2=0.63$):** Ens (앙상블) 모델 → HGB를 중심으로 가중 평균을 구성한 모델이 가장 우수
- **단일 모델 중 최고:** HistGradientBoosting → 기본 모델 중에서 가장 안정적인 예측력
- **CatBoost, PyCaret, AutoML 계열:** 전체적으로 실무 적용에는 부족 → CatBoost는 범주형 변수 확대 필요 / PyCaret은 과도한 평균 회귀 현상
- **정상성 기반 XGB:** 시계열적 신뢰성은 높으나 성능은 다소 낮음
- **연간 예측 모델**은 타겟이 달라 직접 비교는 부적절

최종 선택 모델

항목	내용
모델명	앙상블 모델 (Ens = 0.2Ridge + 0.2XGB + 0.2RF + 0.4 HGB)
타겟 변수	산업 생산지수 (prod_index)
데이터셋	option1_merged_exclude_sejong.csv
검증 방식	TimeSeriesSplit (3분할 시계열 교차검증)
입력 변수	전력사용량, 기후, 수출, 설비가동률 등 + lag/rolling 파생변수

성능 요약

지표	값	해석
R^2	0.6332	전체 생산지수 변동의 약 63.3% 를 설명
RMSE	7.42	평균 오차는 약 ±7.4 단위
MPE	-0.4266%	예측치의 평균 오차율

→ 산업 생산지수의 변동을 63% 이상 설명하는 예측력을 가짐

V. 웹서비스 & DB 설계 및 구축

본 문단은 프로젝트 개요 문단에서 서술한 제조업 생산지수 예측 웹서비스 구현을 위한 웹서비스 구조와 DB 구축 방안을 설명한다.

1. 데이터베이스 ERD 설계

본 프로젝트를 위한 DB는 확장성, 정규화, 성능 최적화, 협업 효율성을 고려하여 MySQL 기반으로 작성함

- DB 설계 개요

- **DBMS:** MySQL
- **주요 목적:** 사용자 맞춤형 예측 서비스 제공을 위한 시계열 데이터 저장, 사용자 설정, 예측 결과, 즐겨찾기 및 인사이트 메시지 등 전체 데이터 흐름 구성
- **설계 방식:** 정규화 기반 ERD 설계 + 외래키 제약조건 및 인덱싱 명시

- 테이블 구성 요약

구분	테이블명	설명
사용자 관련 테이블	users	사용자 계정 및 로그인 정보
	favorites	사용자 즐겨찾기 지역 설정
지역 및 시계열 데이터 테이블	regions	지역 기본 정보 (코드, 이름)
	region_data	지역별 시계열 실제 데이터 (생산지수, 전력, 수출 등)
예측 및 인사이트 테이블	forecast_results	AI 기반 생산지수 예측 결과
	insight_messages	자동 생성된 자연어 인사이트 메시지

- 각 테이블 구성 설계

• 사용자 관련 테이블

▪ users

필드명	타입	설명
id	INT, PK	사용자 고유 ID
email	VARCHAR(100)	사용자 이메일 (유니크)
password_hash	VARCHAR(255)	bcrypt로 암호화된 비밀번호
is_verified	BOOLEAN	이메일 인증 여부
created_at	DATETIME	가입일시
updated_at	DATETIME	정보 수정일시

- favorites

필드명	타입	설명
id	INT, PK	고유 ID
user_id	INT, FK	사용자 ID (users.id)
region_id	INT, FK	지역 ID (regions.id)
created_at	DATETIME	즐거찾기 등록일시

- 지역 및 시계열 데이터 테이블

- regions

필드명	타입	설명
id	INT, PK	지역 고유 ID
name	VARCHAR(100)	지역명 (예: 서울, 부산)
code	VARCHAR(20)	지역 코드 (API 연동용)

- region_data

필드명	타입	설명
id	INT, PK	고유 ID
region_id	INT, FK	지역 ID (regions.id)
date	DATE	기준 월
production_index	FLOAT	제조업 생산지수
power_usage	FLOAT	전력 사용량 (단위: MWh)
export_amount	FLOAT	수출액 (단위: 억원)
temperature_avg	FLOAT	평균기온 (선택 항목)
precipitation	FLOAT	강수량 (선택 항목)
created_at	DATETIME	입력일시

- 예측 및 인사이트 테이블

- forecast_results

필드명	타입	설명
id	INT, PK	고유 ID
region_id	INT, FK	지역 ID (regions.id)
forecast_date	DATE	예측 대상 월
predicted_index	FLOAT	예측된 생산지수
confidence	FLOAT	예측 신뢰도 (0~1 또는 %)
model_version	VARCHAR(20)	예측 모델 버전
created_at	DATETIME	예측 생성일시


▪ insight_messages

필드명	타입	설명
id	INT	PK
regionW_id	INT	FK → regions.id
date	DATE	기준 시점
message	TEXT	자연어 인사이트 메시지
messageW_type	VARCHAR(30)	예: 상승, 하락, 이상징후 등
source	VARCHAR(20)	예: 예측모델, 기초통계
createdW_at	DATETIME	생성일시

- - 데이터 무결성 및 설계 원칙 요약

항목	내용
정규화 수준	3NF (제3정규형) 준수하여 중복 최소화
외래키 제약	사용자/지역 간 관계는 FK로 명시 ON DELETE CASCADE 선택 가능
인덱스 적용	시계열 필드 (date, regionW_id)에 인덱스 구성
유일성 보장	(region_id, date) 조합에 UNIQUE 설정
암호화 저장	password는 bcrypt 등 해시 방식 전제
확장성 확보	지역 외 업종 추가 설계 확장 가능성 고려

- ERD 시각화



2. 데이터베이스 ERD 기반 웹 서비스 기능 정의

• 정보 구조

앞서 설계한 데이터베이스 ERD를 바탕으로 웹 서비스의 기능 및 정보 구조를 설계한다. 본 시스템은 사용자가 제조업 생산지수를 직관적으로 이해하고, 지역별 경기 흐름을 예측할 수 있도록 설계되었다. 전체 서비스는 대시보드 중심으로 구성되며, 지역 분석과 예측 상세 페이지를 통해 분석 및 활용이 가능하다.

• 홈페이지 (/)

- 사용자가 접속 시 가장 먼저 보게 되는 메인 대시보드로, 생산지수 요약, 예측값, 인사이트 메시지를 한눈에 확인할 수 있다.

• 지역별 분석 페이지 (/region)

- 지역 단위의 생산지수, 전력 사용량, 수출 데이터를 비교하고 탐색할 수 있는 화면이다. 필터와 정렬 기능을 통해 원하는 정보를 빠르게 탐색 가능하다.

• 예측 상세 페이지 (/region/:id)

- 선택한 지역에 대한 예측 결과를 상세히 확인할 수 있는 페이지로, 실제값과 예측값 비교, 주요 원인 변수 분석, 자연어 기반 인사이트를 함께 제공한다.

• 즐겨찾기 페이지 (/favorites)

- 사용자가 저장한 관심 지역을 모아보고, 재방문 시 손쉽게 접근할 수 있도록 구성된 개인화 화면이다.

• 로그인 및 인증 관련 페이지 (/login, /signup, /reset)

- 사용자 인증을 위한 로그인, 회원가입, 비밀번호 찾기 및 재설정 기능을 제공한다. 모든 개인화 기능은 로그인 상태에서만 사용 가능하다.

■ 기능 명세서

시스템에 구현될 핵심 기능들을 정리하였으며, 각 기능은 사용자 편의성과 데이터 기반 해석 제공을 목표로 설계됨.

기능명	설명
회원가입	사용자가 이메일과 비밀번호를 등록하고 약관에 동의하여 계정을 생성하는 기능. bcrypt 암호화를 통해 보안성 확보.
로그인	등록된 계정으로 시스템에 접속하는 기능. JWT 발급을 통해 인증 및 세션 유지.
로그아웃	현재 로그인된 사용자의 인증 상태를 해제하고, 보안상 로그아웃 처리 수행.
생산지수 요약 표시	최신 제조업 생산지수와 전월 대비 변화량을 카드 형태로 시각화. 주요 흐름을 직관적으로 전달.
예측값 및 신뢰도 표시	다음 달 제조업 생산지수를 AI 기반으로 예측하고, 신뢰도

	(Confidence Score)를 함께 제공.
인사이트 메시지 출력	조건 기반으로 생성된 자연어 해석 메시지를 통해, 생산지수의 변화 원인이나 의미를 사용자에게 전달.
지역 리스트 조회	필터를 적용하여 다양한 지역의 생산지수 및 전력 데이터를 표 형식으로 나열하고 비교 가능하게 함.
지역 상세 예측 분석	선택한 지역의 과거 시계열 데이터와 예측값을 비교해 시각화하고, 예측 신뢰도 및 원인 지표 분석 포함.
즐거찾기 기능	사용자가 관심 있는 지역을 저장하고, 빠르게 접근할 수 있도록 관리하는 기능.
즐거찾기 목록 조회	저장된 지역을 한 눈에 확인하고, 간편하게 상세 예측 결과를 다시 볼 수 있는 기능.
PDF/CSV 다운로드	예측 결과 및 관련 데이터를 PDF 또는 CSV 형태로 다운로드 받아 보관하거나 보고용으로 활용 가능.
비밀번호 재설정	비밀번호 분실 시 이메일 인증을 통해 안전하게 새로운 비밀번호를 설정할 수 있는 기능.
공통 알림 팝업	로그인 필요, 저장 완료, 오류 발생 등 상황에 맞는 메시지를 팝업으로 알려주는 공통 UI 요소.

3. 타겟 사용자 페르소나 및 개별 flowchart 정의


본 프로젝트의 웹 서비스를 어떤 사용자가 있을지 고려해보았을 때, 크게 4가지의 사용자 페르소나를 정의할 수 있으며 그 정의는 각각 아래 표와 같이 나타낼 수 있다.

타겟 유저	특징	원하는 인사이트
투자자	산업·주식 시장에 관심 많음	제조업 흐름 예측 → 주가 판단 참고
중소 제조업체 관리자	수요 예측 & 원가관리 필요	생산지수 예측 → 설비 투자, 인력 계획
정책 및 공공기관 담당자	지역별 산업/경기 모니터링	특정 지역/산업 생산성 추이 파악
산업 기자 / 애널리스트	경제 동향 리포트 작성	"제조업 회복/둔화" 해석 근거 필요


- **공통 특징:** 산업·경제 흐름에 관심 있는 실무자·투자자
- **공통 니즈:** 단순 수치보다 맥락, 예측, 해석 중심 정보를 원함

위 사용자 페르소나 별로 본 프로젝트의 웹 사이트를 어떻게 사용할지에 대한 flowchart를 아래 그림들과 같이 나타낼 수 있다.


1) 투자자 flowchart




2) 중소 제조업체 관리자 flowchart



3) 정책 및 공공기관 담당자 flowchart



4) 산업기자,애널리스트 flowchart



4. 전체 서비스 flowchart

위에서 정의한 데이터베이스 ERD, 정보 구조, 기능 명세서를 바탕으로 전체적인 웹 서비스가 어떻게 흘러가지를 나타내는 서비스 flowchart를 다음과 같이 나타낼 수 있다.

