

유통 데이터 활용 경진대회 | 데이터 모델링 부분

정확한 수요 예측
중소유통회사 경영 효율성 향상

팀명 | 박관용이



Contents

01

분석 개요

분석 목적 및 필요성
기대 효과

02

분석 방법 및 절차

데이터 소개
데이터 전처리
탐색적 데이터 분석
모델링

03

분석 결과

모델 선정
결과 해석

04

활용 방안

추후 활용방안
향후 보완 사항

05

참고 문헌

참고한 문헌



분석 목적


| 고도화된 수요 예측 모델을 통해 중소 유통회사의 경영 효율성을 향상시키고, 이를 통해 고객만족도 상승

현재 중소 유통회사 문제점


부정확한 수요 예측
비효율적인 재고 관리
감소하는 고객 만족도
가격 경쟁력 약화







02. 분석 방법 및 절차



데이터 소개

데이터 분석을 위해 활용된 데이터의 특성

01

지역유통판매데이터

수요 예측 정확화, 구매 패턴 이해,
지역별 마케팅 전략 개발, 재고 최적화 가능

02

2.강수량 및 평균온도 일일 데이터

강수량에 따른 품목별
수요 변화가 있을 것으로 예상됨

03

코로나 일별 확진자 수 데이터

코로나19 확진자 수 변화가 구매 행태 및 판매량에
영향을 미칠 것으로 예상됨

04

소비자 물가지수 데이터

물가 변동이 구매력 및 소비패턴 변화에
영향을 미칠 것으로 예상

05

소비자 심리 지수 (CSI)

소비자의 심리 상태가 구매 의사 결정과
소비품목 변화에 영향을 미칠 것으로 예상

06

개강 여부 데이터

학교의 개강 여부가 특정 상품의 수요에
영향을 미칠 것으로 예상


데이터 전처리 흐름도



01

Text - Mining

원본 데이터에서 상품명 컬럼이
여러개가 존재하여
분석할 상품명만 가져오기 위해
텍스트마이닝 기법으로 추출



상품별 분류

예측 상품 리스트를 이용하여
상품명 분류 키워드 컬럼 추가



특정 상품 데이터 필터링 위함

- 가야산천년수<2L*6> : 8809274240219
- 삼다수2L : 8808244208044
- 박카스F 120ml : 8806011615422
- 레쓰비<175ml*30> : 68801056290308
- 코카콜라<1.5*12> : 8801094012403
- 농심]안성탕면 멀티<40> : 8801043014793
- 농심]신라면 멀티<40> : 8801043014847
- 농심]짜파게티 멀티<40> : 8801043015271
- 오뚜기]진라면매운멀티<120g> : 18801045522286
- 농심]너구리 얼큰멀티<40> : 8801043015028

옵션코드	입수	상품명	상품명_분류_키워드	일일 확진자 수	식료품(소비물가지수)	음료(소비물가지수)
BX	40	오뚜기]진라면매운멀티<120g>	진라면	1020.0	103.0	100.04
BX	40	농심]너구리 얼큰멀티<40>	너구리	1020.0	103.0	100.04
BX	40	농심]신라면 멀티<40>	신라면	1020.0	103.0	100.04
BX	40	농심]짜파게티 멀티<40>	짜파게티	1020.0	103.0	100.04
BX	30	레쓰비<175ml*30>	레쓰비	1020.0	103.0	100.04
...	...	...	...	...	...	...
BX	40	농심]안성탕면 멀티<40>	안성탕면	9585.0	110.9	110.06
BX	30	레쓰비<175ml*30>	레쓰비	9585.0	110.9	110.06
CS	6	가야산천년수<2L*6>	가야산	9585.0	110.9	110.06
BX	40	농심]안성탕면 멀티<40>	안성탕면	9585.0	110.9	110.06
CS	10	박카스F 120ml	박카스	9585.0	110.9	110.06

03

시계열 데이터 구조 생성 | 각 상품의 일별 판매량을 구체화하기 위해 중복 판매 데이터 합산



'상품명_분류_키워드'를 사용하여 특정 상품 데이터 필터링

'판매일' 컬럼 타입을 datetime으로 변경 & 인덱스 설정

같은 '판매일'의 판매수량 합산 & 중복행 제거

결측치 확인 검사 | 품목별 결측치 개수 & 비율 확인




< 결측치 수 (비율) >

1번 품목 Data	: 10 일 (2.6%)	"가야산천년수<2L*6>"
2번 품목 Data	: 27 일 (6.9%)	"삼다수2L"
3번 품목 Data	: 71 일 (18.3%)	"박카스F 120ml"
4번 품목 Data	: 35 일 (9.0%)	"레쓰비<175ml*30>"
5번 품목 Data	: 53 일 (13.6%)	"코카콜라<1.5*12>"
6번 품목 Data	: 12 일 (3.1%)	"농심]안성탕면 멀티<40>"
7번 품목 Data	: 27 일 (6.9%)	"농심]신라면 멀티<40>"
8번 품목 Data	: 23 일 (5.9%)	"농심]짜파게티 멀티<40>"
9번 품목 Data	: 27 일 (6.9%)	"오뚜기]진라면매운멀티<120g>"
10번 품목 Data	: 27 일 (6.9%)	"농심]너구리 얼큰멀티<40>"

결측치 비교 & 처리 | 선형보간법 vs 다중대체 (MICE)

선형보간법



선형보간법 다중대체(MICE)

판매일

2021-01-04	4	4
2021-01-05	14	14
2021-01-06	17	19
2021-01-07	20	20
2021-01-08	10	10
...	...	...
2022-06-24	14	14
2022-06-27	32	32
2022-06-28	13	13
2022-06-29	16	19
2022-06-30	19	19

데이터 Recovery | 손실 데이터 복구

결측치 처리방식을 MICE 선정하였고, 그 결과 결측치가 잘 채워진걸 확인할 수 있다.







이외의 결측치 처리한 추가 데이터는 원본 데이터프레임의 판매일 컬럼 기준으로 병합

	판매수량	상품명	일일 확진자 수	지점	강수량(mm)	식료품(소비물가지수)	음료(소비물가지수)	소비자심리지수	개강여부	탄산음료
판매일										
2021-01-04	258.0	가야산천년수<2L*6>	1020.0	전국	0.0	103.0	100.04	95.4	0.0	103.27
2021-01-05	83.0	가야산천년수<2L*6>	715.0	전국	0.1	103.0	100.04	95.4	0.0	103.27
2021-01-06	90.0	가야산천년수<2L*6>	839.0	전국	0.9	103.0	100.04	95.4	0.0	103.27
2021-01-07	170.0	가야산천년수<2L*6>	868.0	전국	1.2	103.0	100.04	95.4	0.0	103.27
2021-01-08	179.0	가야산천년수<2L*6>	672.0	전국	0.0	103.0	100.04	95.4	0.0	103.27
...	...	...	...	...	...	...	...	...	...	...
2022-06-24	208.0	가야산천년수<2L*6>	7210.0	전국	26.1	110.9	110.06	96.7	0.5	114.29
2022-06-27	171.0	가야산천년수<2L*6>	3429.0	전국	13.4	110.9	110.06	96.7	0.5	114.29
2022-06-28	59.0	가야산천년수<2L*6>	9871.0	전국	2.0	110.9	110.06	96.7	0.5	114.29
2022-06-29	504.0	가야산천년수<2L*6>	10437.0	전국	20.9	110.9	110.06	96.7	0.5	114.29
2022-06-30	114.0	가야산천년수<2L*6>	9585.0	전국	35.8	110.9	110.06	96.7	0.5	114.29




390 rows × 10 columns

데이터 분포도






이상치 제거 후 데이터 분포도

Winsorizing 방식



이상치 제거 후 정규분포




EDA 분석 결과


| 탐색적 데이터 분석(EDA)

월별 및 분기별 판매 수량에서 큰 변화가 있는 품목을 확인

월별 판매수량 그래프



분기별 판매수량 그래프






대다수의 품목이
정규분포

삼다수 제외 모든 품목
계절성 확인

	가야산천 년수 <2L*6>	삼다수 2L	박카스F 120ml	레쓰비 <175ml*30>	코카콜라 <1.5*12>	농심]안성탕 면 멀티 <40>	농심]신라 면 멀티 <40>	농심]짜파게 티 멀티 <40>	오뚜기]진라 면매운멀티 <120g>	농심]너구리 얼큰멀티 <40>
1 분기	20.47%	27.56%	18.88%	20.67%	32.82%	21.52%	21.64%	22.48%	21.11%	24.95%
2 분기	26.74%	23.38%	28.07%	22.57%	26.51%	25.84%	18.38%	20.17%	29.23%	22.07%
3 분기	31.93%	26.39%	26.83%	31.78%	14.64%	29.19%	31.96%	27.27%	31.09%	29.32%
4 분기	20.86%	22.68%	26.22%	24.98%	26.03%	23.45%	28.02%	30.08%	18.57%	23.66%



시계열 모델링

시계열 구조 | STL(Seasonal and Trend decomposition using Losses) 분해



시계열 모델링


다변량 분석 | 주성분 분석 (PCA) , 히트맵 (Heatmap)



해석 결과 | 6 개의 주성분이 전체 분산의 약 97.2%를 설명

군집 분석 | 해석 결과


제외된 품목인 '너구리 얼큰멀티<40>'를 제외하고, 모든 품목군에서는 4개의 군집으로 최적 분류됨
주성분 분석 결과, 4개의 주성분으로 전체 분산의 91.2%를 설명 가능하며,
3개의 주성분만으로도 87.6%의 설명력을 보유함



주성분 군집분석 | 해석 결과

품목군별 영향력이 가장 큰 주성분 3개로 집계하여 분석한 결과
'일일확진자수', '강수량', '품목별 소비자심리지수'가 선정


[3D 산점도]




3개 주성분으로
DataFrame 재구성

시계열 교차 검증

시계열 데이터에 특화된 모델의 성능을 보다 정확하고
실제적으로 평가하기 위한 필수적인 절차





[LSTM 단변량 이상치O 모델 교차검증]



LSTM 딥러닝 모델


< 다변량 모델 >





머신러닝 모델

ProPhet 모델 | Facebook 에서 개발한 시계열 예측 모델


[1년 예측값]




[2년 예측값]



[6개월 예측값]




03. 분석 결과



최종 선정 모델

데이터 분석 결과 | ProPhet 모델

모델 성능 평가



예측 모델 정확도 가장 높은 모델 | ProPhet


MAE 가 낮을 수록 성능이 좋기 때문에
전처리된 ProPhet 모델을 선정함

ProPhet 모델 선정 이유

결과의 의미와 해석

Prophet 모델 | 결과

[머신러닝 MAE]



머신러닝의
Prophet

예측 정확도




딥러닝의
LSTM


예측정확도 높은 방법

계절성(Seasonality)
추세(Trend)
잔차(Residual)
학습과정에 적용

결측치 처리
이상치 처리



04. 활용 방안



추후 활용방안

물류창고 최적화 임대 솔루션

현재 대다수의 중소물류업체는 고정된 공간을 대여함으로써
공간비효율성이 심각한 상황

미래 수요 예측을 통해 상품을 시즌성, 비 시즌성으로 분류

비 시즌성 상품은 정기적 발주로 창고 공간 최소화
시즌성 상품은 예측 모델로 호황과 불황을 파악하여
기간별 품목 수용 최적화 도출

중소유통업체의 경쟁력 강화와 임대료절감효과를 기대



소상공인 CPG 마케팅 가이드 제공

현재 많은 소매점들이 개인의 직관 혹은 개인화된 데이터에 의존해
CPG(Consumer Packaged Goods) 마케팅을 진행 중

소매점의 특성(시기, 형태, 면적, 위치)에 따른 예상 수요량과
CPG 마케팅 효과를 소상공인에게 제공 예정
또한, 변화하는 환경에 맞는 마케팅 가이드라인도 함께 제시

이 서비스를 통해 소상공인은 매출 증가와 지역 소비 활성화 기대



향후 보완 사항

보완 사항 1



데이터 품질 개선

수요 예측의 정밀도는 데이터 품질에 직결됨
그렇기에 데이터 클렌징, 전처리, 결측치 처리의
효과적인 방법을 연구하는 것이 중요


보완 사항 2



다변량 및 복잡한 패턴 예측


다수의 모델이 단일 변수 예측에 집중하는 반면,
실세계는 복합적인 다변량 패턴을 가짐
이에 대한 효율적인 예측 방법 연구가 필요

보완 사항 3




실시간 예측

실시간 수요 예측 능력을 갖춘 모델의 개발이 중요하며,
이에 따른 스트리밍 데이터 처리와 분석을 위한 알고리
즘 및 프레임워크 연구가 필요



05. 참고 문헌



활용 데이터

| 참고 문헌

01

유통데이터 활용 경진대회 대회 제공용 데이터 (필수/참고용 데이터)

02

코로나 데이터(확진자 수) 보건복지부_출처

03

일일 강수량 데이터 기상청_출처

04

소비자 물가지수 KOSIS국가통계포털 출처

05

소비자 심리지수 KOSIS국가통계포털 출처

참고한 문헌

| 참고 문헌

01

기상데이터를 활용한 유통수요예측

기상청 출처